
Generación de árboles de comportamiento de
personajes no jugador mediante grandes
modelos de lenguaje
Generation of Non-Player Character Behavior
Trees Using Large Language Models



Trabajo de Fin de Máster
Curso 2025–2026

Autor

Pablo Sánchez Martín

Director

Carlos León Aznar, Ismael Sagredo Olivenza

Máster en Inteligencia Artificial

Facultad de Informática

Universidad Complutense de Madrid

Generación de árboles de comportamiento
de personajes no jugador mediante
grandes modelos de lenguaje
Generation of Non-Player Character
Behavior Trees Using Large Language
Models

Trabajo de Fin de Máster en Máster de Inteligencia Artificial

Autor

Pablo Sánchez Martín

Director

Carlos León Aznar, Ismael Sagredo Olivenza

Dirigida por el Doctor

Carlos León Aznar, Ismael Sagredo Olivenza

Máster en Inteligencia Artificial

Facultad de Informática

Universidad Complutense de Madrid

2 de septiembre de 2026

Dedicatoria

*A toda la gente que quiero,
a los que me han apoyado y a los que me han
hecho crecer.
A todos los que han estado a mi lado.*

Agradecimientos

A mi familia: mi madre, mi hermana, su recién marido, mis tíos y mis primos por haber soportado otro año más de mis estreses académicos. A David y a María, por estar todos los días a mi lado y haber hecho que ir a clase haya sido tan divertido. A mis amigos de la universidad, por soportarme todos los días, escucharme y hacer más amenos mis días. A mis amigos del instituto y del colegio, por seguir a mi lado apoyándome y animándome cuando lo necesito. A aquellos profesores que, un año más, han estado a mi lado ayudándome a evolucionar, soportándome y dándome su ayuda en los momentos que lo he necesitado. En especial, a mis tutores, Carlos e Isma, por estar conmigo en todo y ofrecerme desde un principio un tiempo que no les sobra.

Resumen

Generación de árboles de comportamiento de personajes no jugador mediante grandes modelos de lenguaje

Este estudio se centra en la creación de una herramienta que, mediante grandes modelos de lenguaje, sea capaz de generar árboles de comportamiento (BTs) para personajes no jugador (NPCs) que sirvan como base con el fin de aliviar la carga de trabajo de los diseñadores.

Para ello se ha elegido el motor de videojuegos Unreal Engine 5 para implementar una serie de acciones y condicionales que servirán como nodos para los BTs generados, así como para diseñar una serie de escenarios que sirvan como entornos de pruebas en los que se puedan ejecutar los BTs. Una vez se han contado con una serie de nodos y entornos de ejecución se ha procedido al diseño de la herramienta. Finalmente se decidió por una implementación en la que el modelo “Mistral-large-3” procesase el comportamiento escrito en lenguaje natural en un pseudocódigo que se traducía a una estructura de árbol en formato JSON, mientras que un segundo modelo más pequeño, el modelo “llama3:8B” se dedicaba a la asignación de variables de la Blackboard (módulo de memoria del BT). Una vez se genera el BT se han implementado dos formas de validación automática y posible corrección, un autómata finito no determinista (NFA) que valida si el orden de los nodos respeta posibles dependencias entre ellos, y un validador que, al terminar la ejecución, verifica si se han cumplido ciertos objetivos planteados para el comportamiento. Al tener el sistema planteado se han diseñado unas pruebas de usuario para comprobar si la herramienta es intuitiva y genera BTs de una calidad similar a los que crea un humano en un tiempo inferior. Las pruebas se han realizado con una muestra de $N = 3$ usuarios, por lo que no se pueden tomar conclusiones definitivas. Sin embargo, se ha observado que los usuarios encontraban la herramienta fácil de usar (con una puntuación SUS de 90.83/100) y que generaban los BTs en un tiempo inferior a los humanos con una calidad ligeramente inferior, cumpliendo así con el objetivo de la herramienta.

Palabras clave

IA, Árboles de comportamiento, Comportamiento de NPCs, Procesamiento del lenguaje natural, LLM

Abstract

Generation of Non-Player Character Behavior Trees Using Large Language Models

This study focuses on creating a tool that, using large language models, is capable of generating behavior trees (BTs) for non-player characters (NPCs) to serve as a foundation for reducing the workload of designers.

To this end, the Unreal Engine 5 video game engine was chosen to implement a series of actions and conditionals that will serve as nodes for the generated BTs, as well as to design a series of scenarios that will serve as test environments in which the BTs can be executed. Once a set of nodes and execution environments was in place, the tool was designed. Finally, an implementation was chosen in which the “Mistral-large-3” model processed the behavior written in natural language into pseudocode that was translated into a tree structure in JSON format, while a second, smaller model, the “llama3:8B” model, was dedicated to assigning variables in the Blackboard (the BT’s memory module). Once the BT is generated, two methods for automatic validation and potential correction have been implemented: a non-deterministic finite automaton (NFA) that validates whether the order of the nodes respects any dependencies between them, and a validator that, upon completion of execution, verifies whether certain objectives set for the behavior have been met. Once the system was set up, user tests were designed to verify whether the tool is intuitive and generates BTs of a quality similar to those created by a human in less time. The tests were conducted with a sample of $N = 3$ users, so no definitive conclusions can be drawn. However, it was observed that users found the tool easy to use (with an SUS score of 90.83/100) and that it generated BTs in less time than humans, albeit with slightly lower quality, thus meeting the tool’s objective.

Keywords

AI, Behavior Trees, NPC Behavior, Natural Language Processing, LLM

Índice

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	3
1.3. Plan de trabajo	4
2. Estado de la Cuestión	5
2.1. Comportamientos de NPCs en videojuegos	5
2.1.1. Máquinas de estado finitas	5
2.1.2. Máquinas de estado finitas jerárquicas	6
2.1.3. Árboles de comportamiento	8
2.1.3.1. Behavior Trees en Unreal Engine	9
2.2. Modelos de lenguaje	10
2.3. Generación automática de comportamientos	15
2.3.1. Generación de Behavior Trees previos a LLMs	15
2.4. Generación de Behavior Trees mediante LLMs en la robótica	16
2.5. Generación de Behavior Trees mediante LLMs en videojuegos	17
3. Descripción del Trabajo	19
3.1. Diseño del modelo propuesto de la herramienta de generación de árboles de comportamiento	20
3.2. Descripción del entorno	20
3.2.1. Tareas y condicionales	21
3.2.2. Formato del árbol de comportamiento generado	23
3.3. Generación de los Behavior Trees	24
3.3.1. Generación de forma directa	24
3.3.2. Generación mediante fragmentación por subtareas	25
3.3.3. Generación mediante pseudocódigo	26
3.4. Validación automática de los Behavior Trees	30
3.4.1. Validación de dependencias	32
3.4.2. Validación de objetivos	33
3.4.3. Entornos creados para la validación	33

4. Pruebas con usuarios	37
5. Pruebas con usuarios	45
6. Resultados	53
6.1. Resultados de los escenarios	53
6.2. Resultados de la herramienta generadora de árboles de comportamiento	54
6.3. Resultados del sistema de validación automática	54
6.4. Resultados de las pruebas de usuarios	55
7. Conclusiones y Trabajo Futuro	57
7.1. Conclusiones	57
7.2. Limitaciones	57
7.3. Trabajo Futuro	58
Introduction	59
7.4. Motivation	59
7.5. Objectives	60
7.6. Work Plan	60
Conclusions and Future Work	63
7.7. Conclusions	63
7.7.1. Dataset Search Conclusions	63
7.7.2. Conclusions of the Animation Extraction Tool	63
7.7.3. Conclusions of the User Data Collection	64
7.7.4. Conclusions of the IA Models Comparison	64
7.7.5. Final Application Conclusions	64
7.7.6. Limitations	64
7.8. Future Work	65
Bibliografía	67
A. JSON Schema para los Behavior Trees generados	75
B. Prompt del sistema para el LLM generador del pseudocódigo	79
C. JSON de dependencias de tareas en un Behavior Tree	81
D. Formulario de opiniones de la herramienta	83
Glosario	89
Licencia de uso del documento	91
Licencia de uso del código fuente	93

Índice de figuras

2.1.	Ejemplo de un FSM para videojuegos	6
2.2.	Ejemplo de una HFSM en videojuegos	7
2.3.	Captura del sistema de animaciones de Unity Engine	7
2.4.	Ejemplo de Behavior Tree	8
2.5.	Ejemplo de Behavior Tree de Unreal Engine	10
2.6.	arquitectura de un modelo Transformer	12
2.7.	Arquitectura MCP	15
3.1.	Diagrama de la herramienta propuesta	20
3.2.	Entorno de desarrollo	21
3.3.	Generación mediante subtareas	26
3.4.	Ejemplo del pseudocódigo que el LLM debe generar.	27
3.5.	Chain-of-Thought del LLM que genera el pseudocódigo.	29
3.6.	Ejemplo del input y el output del LLM que establece las variables de la Blackboard.	31
3.7.	Captura de pantalla del segundo entorno	34
3.8.	Captura de pantalla del tercer entorno	34
4.1.	Resultados de la encuesta SUS	39
4.2.	Comparación de los tiempos de generación de los BTs	40
4.3.	Opinión de los usuarios sobre los tiempos de generación de los BTs . .	41
4.4.	Opinión de la calidad de los BT	42
4.5.	Opinión de los usuarios sobre la ejecución esperada de los BTs	42
4.6.	Opinión sobre si los BT son un buen punto de partida	43
4.7.	Opinión de los usuarios sobre si los resultados del BT generado son fácilmente modificables	44
4.8.	Opinión de los usuarios sobre si disminuye la carga de trabajo de los diseñadores.	44
5.1.	Resultados de la encuesta SUS	47
5.2.	Comparación de los tiempos de generación de los BTs	48
5.3.	Opinión de los usuarios sobre los tiempos de generación de los BTs . .	49
5.4.	Opinión de la calidad de los BT	50

5.5.	Opinión de los usuarios sobre la ejecución esperada de los BTs	50
5.6.	Opinión sobre si los BT son un buen punto de partida	51
5.7.	Opinión de los usuarios sobre si los resultados del BT generado son fácilmente modificables	52
5.8.	Opinión de los usuarios sobre si disminuye la carga de trabajo de los diseñadores.	52
7.1.	Gantt chart of the project	61
B.1.	Prompt del sistema para el LLM generador del pseudocódigo	80
D.1.	Formulario de recogida de datos demográficos (primera parte)	84
D.2.	Formulario de recogida de datos demográficos (segunda parte)	85
D.3.	Formulario de recogida de datos demográficos (tercera parte)	86
D.4.	Formulario de recogida de datos demográficos (cuarta parte)	87

Índice de tablas

3.1. Modelos probados para la generación directa del JSON mediante guidance.	24
3.2. Resultados de las pruebas de validación	35
4.1. Resultados de la encuesta SUS	39
4.2. Tiempo (en segundos) de generación de cada BT por cada usuario . .	40
5.1. Resultados de la encuesta SUS	47
5.2. Tiempo (en segundos) de generación de cada BT por cada usuario . .	48

Introducción

Los videojuegos están compuestos por múltiples elementos que interactúan entre sí para construir una experiencia coherente e inmersiva para el jugador, entre los que se encuentran el avatar del jugador, los escenarios, los objetos interactivos y, de forma habitual, los personajes no jugables. Estos personajes no jugables (NPC, por sus siglas en inglés de Non-Player Character) desempeñan un papel relevante en la construcción de mundos virtuales, ya que son responsables de proporcionar interacciones, responder a las acciones del jugador y desarrollar comportamientos coherentes con el contexto del juego.

El desarrollo de estos comportamientos constituye una tarea que involucra tanto aspectos de diseño como de implementación. Habitualmente, los diseñadores determinan las acciones, rutinas e interacciones que debe desarrollar un NPC, mientras que los programadores se encargan de trasladar estas especificaciones a una implementación ejecutable. Para ello pueden emplearse diferentes técnicas de inteligencia artificial, entre las que destacan las máquinas de estados finitos (Finite State Machines, FSM) y los árboles de comportamiento (Behavior Trees, BT), siendo estos últimos el principal objeto de estudio de este trabajo.

El desarrollo de comportamientos para NPCs es, además, un proceso inherentemente iterativo. Durante la implementación es necesario comprobar el comportamiento obtenido, detectar situaciones no previstas y modificar la lógica para adaptarla a los requisitos del juego. Como consecuencia, diseñadores y programadores pueden verse obligados a repetir sucesivamente las fases de diseño, implementación, evaluación y modificación de los comportamientos. En el caso de los árboles de comportamiento, estos cambios implican con frecuencia crear, reorganizar o modificar nodos, condiciones y relaciones de ejecución, lo que puede incrementar el esfuerzo necesario a medida que aumenta la complejidad del comportamiento.

A este coste de desarrollo se añade la necesidad de disponer de conocimientos técnicos específicos para construir y modificar correctamente estas estructuras. La utilización de un sistema basado en árboles de comportamiento requiere comprender tanto su lógica de ejecución como los elementos que lo componen y sus relaciones, lo que puede dificultar su utilización por parte de desarrolladores con menor experiencia en inteligencia artificial o por perfiles no especializados en programación.

En este contexto, la generación automática de árboles de comportamiento a par-

tir de descripciones realizadas en lenguaje natural constituye una posible vía para reducir el esfuerzo asociado a su creación y modificación. Permitir que un usuario pueda describir el comportamiento deseado mediante una especificación en lenguaje natural y obtener de forma automática una estructura ejecutable podría reducir parte del trabajo manual necesario durante el desarrollo, facilitar la iteración sobre los comportamientos y disminuir las barreras técnicas asociadas a su implementación.

La aparición de los Large Language Models (LLMs), capaces de interpretar instrucciones en lenguaje natural y generar estructuras complejas a partir de ellas, abre una nueva posibilidad para automatizar este proceso. Por este motivo, este trabajo estudia la utilización de modelos de lenguaje para la generación automática de árboles de comportamiento destinados al control de personajes no jugables, analizando las posibilidades y limitaciones de este enfoque en el contexto del desarrollo de videojuegos.

1.1. Motivación

La creciente complejidad de los videojuegos ha incrementado también la complejidad de los comportamientos que deben implementar sus personajes no jugables. A medida que se incorporan un mayor número de acciones, situaciones y posibilidades de interacción, las estructuras encargadas de controlar estos comportamientos requieren un mayor número de elementos y relaciones entre ellos. En este contexto, los Behavior Trees presentan características como la modularidad y la escalabilidad que resultan especialmente adecuadas para representar comportamientos complejos (Lim et al. (2010)).

Sin embargo, estas características no eliminan el coste asociado a la creación y mantenimiento de los árboles. La construcción manual de comportamientos puede resultar laboriosa y requerir conocimientos especializados, especialmente cuando los comportamientos deben modificarse o ampliarse de manera iterativa. La literatura señala precisamente el esfuerzo que supone para los diseñadores desarrollar comportamientos de NPC y proponen mecanismos destinados a automatizar su expansión (Florez-Puga et al. (2008)). Asimismo, hay artículos que ponen de manifiesto la necesidad de facilitar la interacción entre los aspectos de diseño y los aspectos técnicos de la implementación de comportamientos (Llansó et al. (2009)).

La dificultad de autoría de los Behavior Trees también ha motivado la investigación de herramientas destinadas a facilitar su creación. Hay autores que proponen una herramienta de autoría basada en una interfaz visual que busca simplificar la construcción de estos árboles y acercar su edición al proceso de diseño (Becroft et al. (2011)). Estos trabajos muestran que la reducción del esfuerzo necesario para especificar y modificar comportamientos constituye una problemática anterior a la aparición de los Large Language Models.

Como consecuencia, se han desarrollado diferentes aproximaciones para automatizar total o parcialmente la construcción de Behavior Trees. Entre ellas se encuentran métodos basados en la reutilización de comportamientos, técnicas de evolución automática y métodos de síntesis a partir de especificaciones formales, demostrando que la generación de árboles de comportamiento constituye una línea de investiga-

ción consolidada. Estas aproximaciones permiten reducir parte del trabajo manual, aunque generalmente requieren representaciones estructuradas del problema, funciones de evaluación, demostraciones o conocimientos específicos del dominio.

La aparición de los Large Language Models introduce una nueva posibilidad para abordar este problema, ya que estos modelos permiten procesar instrucciones expresadas en lenguaje natural y generar estructuras a partir de ellas. En lugar de requerir que el usuario defina directamente la estructura interna del Behavior Tree, puede plantearse que describa el comportamiento deseado mediante lenguaje natural y que el sistema se encargue de realizar la traducción a una representación estructurada. Esta aproximación permite explorar una interacción más cercana al proceso de diseño y puede reducir las barreras técnicas asociadas a la autoría de comportamientos.

En este contexto, este trabajo se sitúa en la intersección entre la investigación sobre generación automática de Behavior Trees y los avances recientes en Large Language Models.

1.2. Objetivos

El objetivo general de este proyecto es la implementación de una herramienta que puedan usar de forma sencilla e intuitiva diseñadores, tanto expertos como los que no tienen una base técnica, para poder generar [Behavior Trees](#) de una manera más eficaz que los que puedan generar ellos y con una calidad similar a la humana con el fin de aliviar su trabajo. No se busca sustituir el trabajo de un diseñador, sino aportarles una base útil que les devuelva unas estructuras fácilmente modificables para matizar ciertos aspectos o cambiar de forma sencilla los comportamientos generados. Para cumplir estos objetivos se han propuesto las siguientes metas durante el trabajo:

- Implementación de una pila de tareas y condicionales necesarias para generar diferentes comportamientos.
- Diseño e implementación de diferentes escenarios en los que se pueda probar en tiempo real y de forma visual los comportamientos buscados.
- Comparar diferentes métodos de implementación y modelos de lenguaje (tiempos de ejecución y calidad de las generaciones) para elegir el idóneo para cumplir el objetivo general.
- Implementación de la herramienta generadora usando diferentes técnicas de [IA](#) que consigan una generación óptima.
- Implementación un sistema de validación de los [Behavior Trees](#) generados para comprobar que son válidos en cuanto a respeto de dependencias de nodos y cumplimiento de objetivos.
- Realizar un plan de pruebas para validar el cumplimiento de los objetivos generales.

1.3. Plan de trabajo

El plan de trabajo consiste en varios pasos:

1. Desarrollo e implementación de varios escenarios en un motor de videojuegos que contengan lo necesario para la generación: una pila de tareas y condicionales, capacidad para ejecutar los [Behavior Trees](#) generados y una forma de comunicarse con la herramienta de generación.
2. Implementación de una herramienta que, mediante grandes modelos de lenguaje, sea capaz de generar [Behavior Trees](#) a través del lenguaje natural capaces de satisfacer un comportamiento buscado.
3. Desarrollo de un sistema de validación automática de los [Behavior Trees](#) generados.
4. Diseño y posterior ejecución de pruebas con usuarios objetivo para medir el correcto cumplimiento de los objetivos.

Capítulo 2

Estado de la Cuestión

En este capítulo se presenta el estado del arte de los distintos elementos que componen el trabajo. Estos campos son los comportamientos de **NPCs** en videojuegos, los modelos de lenguaje y la generación automática de comportamientos.

2.1. Comportamientos de **NPCs** en videojuegos

Como bien se ha mencionado en la sección 1, a medida que los videojuegos han ido creciendo y evolucionando se han tenido que utilizar diferentes técnicas para modelar comportamientos cada vez más grandes y complejos, como se puede ver en [Gajardo et al. \(2019\)](#).

2.1.1. Máquinas de estado finitas

Las máquinas de estados finitas (FSM según las siglas en inglés de Finite State Machine) se definen según [Ben-Ari y Mondada \(2018\)](#) como un conjunto de estados s_i y un conjunto de transiciones s_i, s_j que están definidas por una relación de tipo acción/condición, donde la condición actúa como el evento desencadenante para realizar la transición y la acción representa la tarea específica que se ejecuta al cambiar de estado. Según su definición se puede ver que resulta muy útil para modelar el comportamiento en los videojuegos, como se puede ver en la figura 2.1, ya que se pueden ver a los **NPCs** como agentes que realizan acciones (permanecen en estados) constantemente, siendo las transiciones la terminación de las acciones (cuando pasan a un estado siguiente) o un factor externo.




Figura 2.1: Ejemplo de un comportamiento típico de un NPCs mediante una FSM. Fuente: <https://code.tutsplus.com/es/maquinas-de-estados-finitos-teoria-e-implementacion--gamedev-11867t>

Esto se puede ver en trabajos como Fathoni et al. (2020), donde los autores presentan un videojuego en el que implementan las FSM en diferentes NPCs para que muestren un comportamiento más consistente, realista y reactivo por su simplicidad a la hora de desarrollar, dando como resultado un comportamiento inteligente y autónomo. Otro ejemplo del uso histórico de las FSMs en videojuegos se puede ver en Lee (2014), donde los autores implementan una FSM con probabilidad de transiciones distinta a 1 para emular de forma más realista el comportamiento de caza de los lobos, logrando así una experiencia más realista e inmersiva para el usuario. Sin embargo, las FSM no están tan extendidas actualmente, ya que autores como Hu et al. (2011) están de acuerdo en que las FSM tienen un problema de reutilización, flexibilidad y escalabilidad con comportamientos complejos. Aún así, actualmente se siguen utilizando como se puede ver en trabajos recientes como Ganapathi et al. (2024), donde implementan FSM de forma clásica para NPCs o en KimDongju y KohSeok-Joo (2025), donde combinan FSM con técnicas de Machine Learning como Q-Learning y DQN para controlar NPCs de un RPG.

2.1.2. Máquinas de estado finitas jerárquicas

Las máquinas de estado finitas jerárquicas (HFSM por las siglas en inglés de Hierarchical Finite State Machines) se define en Yannakakis (2001) como una extensión de una FSM cuyos estados puedan ser otras FSM contenidas (llamados “superestados”). Aunque todas las HFSM se pueden convertir en FSM mediante un proceso de *flattering* reemplazando de forma recursiva los superestados por sus máquinas internas, las HFSM han solucionado problemas de reutilización de componentes y simplicidad descriptiva. Esta reutilización ha permitido que se extendiese su uso en videojuegos, como mencionan los autores en el trabajo citado anteriormente Hu et al. (2011), con un rendimiento ligeramente mejor o similar a las FSM, como pudieron comprobar los autores en una comparativa realizada en Fauzi et al. (2019). En la

figura 2.2 se muestra un ejemplo de una HFSM en videojuegos.




Figura 2.2: Ejemplo de un comportamiento de un NPC modelado en una HFSM. Fuente: Hu et al. (2011).

De forma comercial también se han usado las HFSM, como se puede ver en Thompson (2018). Otra forma de uso de las HFSM en videojuegos no es para comportamientos de NPCs, sino para simplificar el sistema de animaciones de videojuegos, como se puede ver en trabajos como Nur Fitriani Dewi et al. (2023). El motor de videojuegos Unity Engine también estructura su sistema de animaciones¹ en forma de HFSM para la simplicidad del usuario, como se puede apreciar en el estado de color naranja (estado “Idle”) de la figura 2.3.




Figura 2.3: Captura del sistema de animaciones de Unity, estructurado en forma de una HFSM en la que los nodos naranja son “superestados”. Fuente: <https://docs.unity3d.com/560/Documentation/Manual/StateMachineBasics.html>

¹Enlace a la documentación de Unity: <https://docs.unity3d.com/6000.7/Documentation/Manual/AnimationStateMachines.html>

A pesar de aliviar parcialmente el problema de la duplicidad de código, autores como Sekhavat (2017) argumentan que las HFSM siguen manteniendo problemas de escalabilidad y reutilización en videojuegos; y en el trabajo de Iovino et al. (2025) los autores comentan que sigue siendo difícil de escalar.

2.1.3. Árboles de comportamiento

Los árboles de comportamiento (conocidos como Behavior Trees) se definen en Colledanchise y Ogren (2016) como árboles dirigidos formados por dos tipos de nodos: nodos hoja y nodos de composición en las que las transiciones no son unidireccionales (a diferencia de las FSM y las HFSM), sino llamadas de función bidireccionales en las que el nodo padre envía una señal periódica de activación y el hijo le responde con tres posibles estados: “Success”, “Failure” o “Running”. Un ejemplo de Behavior Tree lo podemos encontrar en la figura ??.




Figura 2.4: Ejemplo de un Behavior Tree para un NPC que debe pasar por una puerta. Fuente: <https://outforafight.wordpress.com/2014/07/15/behaviour-behavior-trees-for-ai-dudes-part-1/>

Como podemos ver en Iovino et al. (2022), los Behavior Trees surgieron en el mundo de la programación de IA de los videojuegos (estableciendo el videojuego Halo 2 como hito histórico) como forma de solucionar los problemas de escalabilidad, acoplamiento, adaptabilidad y reutilización que presentaban las FSM. Además, el mismo artículo comenta que este modelo resultó ser muy valioso también para la robótica, como menciona también la revisión de Iovino et al. (2020a) o en trabajos como Ögren y Sprague (2022). Actualmente hay bastante literatura sobre Behavior Trees, sus implementaciones y posibles mejoras. Por ejemplo, el trabajo de Agis et al. (2020) nos habla de Behavior Trees que no son evaluados cada tick sino cuando sucede un evento (llamados Event-Driven Behavior Trees o EDBT), mejorando así la cooperación en entornos multi-agente. También podemos ver en el trabajo de Guo y Hou (2025) varias ampliaciones a los Behavior Trees en videojuegos, como los EDBT, los árboles de comportamiento emocionales (EmBT) que altera dinámicamente la prioridad de los nodos hijos dependiendo de pesos emocionales (aportando así más humanidad a los NPCs) y la evolución de los comportamientos (Evolving

Behavior), **Behavior Trees** que utilizan la programación genética para automatizar su optimización.

Aunque artículos como Tremblay et al. (2026) hablan del uso de los **Behavior Trees** como herramienta estándar de la industria (sin dejar de usar otros métodos como las ya mencionadas FSM), artículos como Gugliermo et al. (2024) mencionan que no existe un consenso sobre la descripción de sus propiedades ni sobre su semántica. Es por ello que este trabajo se va a basar en los **Behavior Trees** de Unreal Engine.

2.1.3.1. **Behavior Trees** en Unreal Engine

Unreal Engine se ha convertido en uno de los principales motores de la industria de los videojuegos, así como en el ámbito de la investigación con **Behavior Trees**, como se puede ver en trabajos como Partlan et al. (2022). Los **Behavior Trees** de Unreal Engine están basados en EDBT, como se menciona en la documentación oficial de Unreal Engine², incrementando de esta manera el rendimiento del juego.

Esto se hace gracias al uso de la **Blackboard**, un componente de memoria que almacena datos y variables de entrada/salida que usa el **Blackboard** para ciertas tomas de decisiones de ejecución.

Los tipos de nodos que proporciona Unreal se dividen en dos tipos: las composiciones y las tareas (a excepción de otros tipos de **Behavior Trees** que también consideran los condicionales como nodos adicionales). Los nodos de tipo tarea son los nodos hoja del árbol y los que aportan la lógica del NPC. Cuando se evalúan estos nodos pueden devolver el estado de “Success”, “Failure”, “In Progress” o “Aborted”.

Los tipos compuestos son nodos que controlan el flujo de ejecución del **Behavior Tree**:

- **Selector**: Ejecuta el primer hijo que cumpla con ciertas condiciones.
- **Sequence**: Ejecuta todos sus hijos en orden o hasta que uno devuelva “Failure”.
- **Simple Parallel**: Tiene dos conexiones: la tarea principal y la rama secundaria. Ejecuta las dos a la vez y se puede configurar para que su ejecución acabe con la tarea principal o tenga que esperar a la rama secundaria.

Como bien se ha mencionado anteriormente los condicionales, llamados “decoradores” en Unreal Engine, no son nodos, sino que se unen a los nodos para comprobar si pueden ser ejecutados o no. A los nodos también se le pueden unir “Servicios”, los cuales se ejecutan cada cierto tiempo determinado mientras su rama esté siendo ejecutada.

En la figura 2.6 se puede ver un ejemplo de un **Behavior Tree** realizado en Unreal Engine.

²Enlace a la documentación oficial de Unreal: <https://dev.epicgames.com/documentation/unreal-engine/behavior-tree-in-unreal-engine---overview?lang=en-US>




Figura 2.5: Ejemplo de un Behavior Tree de Unreal Engine de un NPC que patruya y persigue al jugador. Fuente: <https://dev.epicgames.com/documentation/unreal-engine/behavior-tree-in-unreal-engine---overview>

2.2. Modelos de lenguaje

Los modelos de lenguaje son sistemas de IA diseñados para comprender, procesar y generar texto. Al principio se basaban en modelos de lenguaje estadístico, como podemos ver en Jelinek y Mercer (1980) donde los autores cuentan como gracias al análisis de corpus de textos y el uso de n-gramas (una instancia específica de un modelo de Markov) se conseguían estimar las probabilidades de una palabra gracias a un contexto limitado. Aunque posteriormente surgieron trabajos como Berger et al. (1996), donde usaban el concepto de máxima entropía para que los modelos sean ligeramente sensibles al contexto que mejoraban estos modelos probabilísticos, seguían estando muy limitados por su baja capacidad de contexto y nulo razonamiento detrás de las respuestas.

En el trabajo de Bengio et al. (2003) se introduce un modelo de lenguaje probabilístico neuronal con el fin de aprender una representación distribuida para cada palabra del vocabulario asociándola con un vector continuo de características reales y una función de probabilidad condicional de la siguiente palabra dependiendo de su contexto, consiguiendo una reducción de la perplejidad (métrica de los modelos de lenguaje que mide la precisión de predicción de la siguiente palabra) de entre el 10 % y el 20 % y permitiendo aprovechar contextos de entrada más largos y más distribuidos, no solo teniendo en cuenta las N palabras anteriores. Este trabajo permitió una evolución de modelos de lenguaje probabilísticos a los basados en redes neuronales, como las RNN (donde se habla del primero entrenable en Elman (1990)) o las LSTM (introducidas en Hochreiter y Schmidhuber (1997)). En Cho et al. (2014) se introduce el concepto de las RNN Encoder-Decoder para su uso en traducción de textos, mejorando el flujo de memoria de un RNN convencional y consiguiendo un rendimiento significativamente superior gracias a la preservación automática de estructuras semánticas y sintácticas. A pesar de la mejora que aplicaron las redes neuronales previamente mencionadas frente a los modelos puramente estadísticos,

todavía tenían imperfecciones debido al desvanecimiento de contextos en textos amplios o al amplio coste de procesamiento debido a su secuencialidad. Aún con estas limitaciones los [LSTMs](#) fueron fundamentales en otro hito de los modelos de lenguaje en el trabajo [Peters et al. \(2018\)](#), en donde los autores introducen la arquitectura ELMo (Embeddings for Language Models), la cual gracias a la suma ponderada de los resultados de las capas [LSTMs](#) bidireccionales es capaz de generar una representación vectorial de las palabras ([Embeddings](#)) contextualizada a nivel semántico y sintáctico, a diferencia de las estructuras estáticas que se utilizaban previamente como Word2Vec, introducido en [Mikolov et al. \(2013\)](#).

En el trabajo [Vaswani et al. \(2023\)](#) presentan el modelo Transformer que logra suplir los problemas mencionados de las redes recurrentes. Esto lo consiguen mediante una arquitectura Encoder-Decoder que contiene unos mecanismos de atención multipropósito y una codificación posicional que inyecta información sobre el orden secuencial, prescindiendo así de los mecanismos de recurrencia. Los mecanismos de atención logran relacionar cualquier pareja de tokens de una misma secuencia sin importar la distancia física que les separe, permitiendo aprender dependencias a largo alcance y la paralelización del entrenamiento.




Figura 2.6: Diagrama de las distintas capas de la arquitectura Transformer. Fuente: <https://aws.amazon.com/es/what-is/transformers-in-artificial-intelligence/>

Gracias al surgimiento de los Transformers empezaron a aparecer otras arquitecturas que mejoraban las tareas del procesamiento del lenguaje natural (NLP por las siglas en inglés de Natural Processing Language). Podemos destacar la arquitectura BERT, introducida en el trabajo Devlin et al. (2019). Esta arquitectura utiliza un codificador Transformer bidireccional multipropósito que para el entrenamiento enmascara de forma aleatoria una serie de tokens (Masked Language Model o MLM) para la predicción del siguiente token según su contexto anterior y posterior, logrando así una bidireccionalidad profunda y logrando un mayor desempeño en tareas como reconocimiento de entidades. Para ajustar el modelo a una tarea específica se realiza un **Fine-tuning** en el que se cargan los parámetros preentrenados y se vuelven a entrenar todos de forma conjunta (end-to-end) con datos etiquetados de la tarea

que se busca. Esto difiere y mejora otros modelos de representación del lenguaje como ELMo, cuya estrategia de transferencia se basa en la extracción de características (Feature-Based), donde las representaciones contextuales preentrenadas se integran de forma estática como características adicionales dentro de arquitecturas secundarias.

La idea del entrenamiento previo y posterior [Fine-tuning](#) ya fue mencionada en el artículo [Radford y Narasimhan \(2018\)](#), en donde además introducen el modelo GPT-1. Este modelo utiliza la arquitectura decodificadora de un Transformer multicapa, el cual en el entrenamiento aplica operaciones de autoatención enmascarada sobre los tokens de contexto para predecir la salida para posteriormente aplicarle [Fine-tuning](#) para tareas específicas, consiguiendo una mejora respecto a modelos anteriores en tareas como razonamiento del sentido común o comprensión lectora.

Como evolución del modelo anterior podemos ver en el artículo [Brown et al. \(2020\)](#), donde introducen el modelo GPT-3, cuya arquitectura está basada también un Transformer decoder de 175B de parámetros con la novedad de la introducción de patrones de atención localmente y densamente agrupada de forma alternada. Este artículo también nos presenta el aprendizaje en contexto (In-Context Learning), el cual se basa en conseguir que un modelo de lenguaje consiga realizar una tarea sin necesidad de cambiar los pesos del modelo mediante [Fine-tuning](#), consiguiendo superar la necesidad de grandes cantidades de datos etiquetados. Esto se puede realizar mediante la descripción de la tarea en lenguaje natural y unos pocos ejemplos (few-shot), un ejemplo (one-shot) o ningún ejemplo (zero-shot). Con solo este tipo de aprendizaje el modelo fue capaz de mejorar el rendimiento de varias tareas de NLP como traducción o completado de texto así como de conseguir capacidades emergentes como la aritmética o la generación de noticias sintéticas.

En el artículo [Wei et al. \(2022\)](#) presentan el concepto de Instruction Tuning, el cual mejoran las capacidades de aprendizaje en entornos zero-shot. Lo consiguen mediante el uso de [Fine-tuning](#) sobre una colección de tareas descritas mediante instrucciones en lenguaje natural, presentando el modelo FLAN basado en un Transformer decoder de 137B parámetros. De esta forma mejoraron superar en gran medida al modelo GPT-3 en entornos zero-shot y en menor medida en entornos few-shot.

Junto a estas arquitecturas empezaron a surgir aplicaciones que ofrecían el uso de [LLMs](#) en formato chatbot, como OpenAI³ con ChatGPT o Anthropic⁴ con Claude así como acceso a sus [APIs](#), permitiendo a usuarios no expertos el uso de [LLMs](#) para fines generalistas. También surgieron frameworks de orquestación de modelos como Langchain⁵ o herramientas que permiten la ejecución de modelos en una máquina local, como es el caso de Ollama⁶

Gracias al surgimiento del In-Context Learning y del Instruction Tuning se empezaron a poder pedir tareas específicas a los [LLMs](#) mediante los prompts, aunque se dan casos donde los modelos no consigan una buena precisión. Debido a esto se investigaron diferentes métodos de alinear el razonamiento de los modelos a través

³Página oficial de OpenAI: <https://openai.com/es-ES/>

⁴Página oficial de Anthropic: <https://www.anthropic.com/>

⁵Página oficial de Langchain: <https://www.langchain.com/>

⁶Página oficial de Ollama: <https://ollama.com/>

de refinar el prompt, dando lugar a un conjunto de técnicas que se conocen como *prompt engineering*. Algunas de estas técnicas ya han sido mencionadas anteriormente, como el zero-shot para casos de Instruction Tuning o few-shot/one-shot para In-Context Learning. En el artículo [Wei et al. \(2023\)](#) nos presenta la técnica de Chain-of-Thought, la cual consiste en obligar al modelo a realizar pasos intermedios de razonamiento internamente para mejorar el rendimiento de las tareas complejas. Otra técnica útil para tareas complejas es Least-To-Most Prompting, presentada en el artículo [Zhou et al. \(2023\)](#) y que consiste en descomponer la tarea general en subtareas sucesivos para ir resolviéndolos de manera incremental. En la revisión sistemática [Schulhoff et al. \(2025\)](#) se pueden encontrar 58 técnicas de *prompt engineering*.

Una vez estudiadas las capacidades de razonamiento de los LLMs se abrió un camino para el estudio de agentes LLMs, sistemas autónomos con modelos de lenguaje integrados que son capaces de percibir, planificar e interactuar con su entorno para completar tareas complejas. Los autores del artículo [Yao et al. \(2023\)](#) presentan el paradigma ReAct, en el que un LLM genera alternadamente trazas de razonamiento en lenguaje natural que ayuda al razonamiento para actuar y acciones específicas para la tarea, permitiendo interactuar con el entorno y actuar para razonar. Otro avance hacia los agentes LLM nos lo encontramos en [Schick et al. \(2023\)](#), donde se puede ver como un agente es capaz de interactuar con APIs de forma correcta que le permiten realizar mejor tareas como operaciones aritméticas, además de demostrar que se le puede dar una cierta autonomía de interacción con el entorno sin intervención humana a los LLMs. La revisión sistemática de [rong WEN \(2025\)](#) habla sobre el uso de herramientas (tool calling) en trabajos recientes, organizándolo en cuatro etapas: planificación de la tarea, selección de la herramienta, llamada a la herramienta y respuesta final. En cuanto a la interacción y planificación de los agentes, el artículo [Huang et al. \(2022\)](#) estudia como un LLM puede utilizar feedback del entorno para actualizar de forma interna sus planes; mientras que en [Liu et al. \(2023\)](#) argumentan que un LLM tiene dificultades en temas de planificación a largo plazo, por lo que proponen usar un planificador clásico entre medias cuando el problema está correctamente formalizado para suplir esta carencia. Finalmente, en el artículo [Park et al. \(2023\)](#) introduce un sistema multiagente basado en agentes LLM sociales con una memoria y la capacidad de recuperar experiencias y de planificar, demostrando que el uso de este tipo de agentes consiguen unas interacciones sociales más creíbles que el uso de agentes clásicos. En el artículo [Wang et al. \(2024\)](#) los autores hacen una revisión sistemática sobre agentes autónomos LLM.

Para que los agentes LLM puedan interactuar con herramientas y recursos externos, en el artículo [Hou et al. \(2026\)](#) nos habla sobre el protocolo MCP (Model Context Protocol). Éste es un estándar abierto cuyo objetivo es estandarizar la comunicación bidireccional ente los modelos LLM y las fuentes y herramientas externas mediante el desacople de la implementación de las herramientas de su uso. Para ello se hace el uso de la siguiente arquitectura:

- **MCP Host:** La aplicación que proporciona el entorno de ejecución.
- **MCP Client:** Componente dentro del Host que mantiene la relación con el servidor procesando solicitudes y resupuestas.

- **MCP Server:** Proveedor que expone las herramientas, los recursos y una serie de prompts para plantillas de tareas y flujos de trabajo preconfigurados.

En la figura 2.7 podemos ver un diagrama de la arquitectura MCP.




Figura 2.7: Diagrama de la arquitectura MCP. Fuente: <https://newsletter.diamant-ai.com/p/model-context-protocol-mcp-explained>

2.3. Generación automática de comportamientos

El problema de la generación de comportamientos de forma automática ya existía antes del surgimiento de los **LLMs**, en donde buscaban soluciones mediante algoritmos de **IA** clásica, como podemos ver en Florez-Puga et al. (2008), donde los autores proponen recuperar y reutilizar comportamientos mediante CBR (siglas de Case-Based Reasoning), construyendo dinámicamente el comportamiento del **NPC** a través de una HFSM. Esta sección se va a centrar en los casos de generaciones automáticas de **Behavior Trees**.

2.3.1. Generación de **Behavior Trees** previos a **LLMs**

Desde el surgimiento de los **Behavior Trees** se ha buscado una forma de automatizar el proceso de su creación.

En el trabajo Sagredo-Olivenza et al. (2017) los autores utilizan diferentes técnicas de Machine Learning para generar de forma automática **Behavior Trees**. Primero se utiliza el aprendizaje por demostración (LfD por las siglas en inglés de Learning from Demonstration) de forma que el diseñador realiza la tarea de la que se busca generar el **Behavior Tree**, registrando las trazas del estado del entorno y las tareas que el **NPC** va ejecutando. Una vez se terminan de recoger esas trazas se generan diferentes modelos de Machine Learning que imitan el comportamiento del agente. Si este modelo es un árbol de decisión (creado el algoritmo de aprendizaje supervisado C4.5), éste se aplanar mediante una búsqueda en profundidad (DFS) para generar reglas lógicas y se unen mediante operadores AND y OR y, usando un algoritmo voraz,

simplifica los nodos redundantes hasta construir el **Behavior Tree** componiéndolo en un nodo de tipo “Parallel” o “Selector”.

En el campo de la programación genética también se han hecho avances en este aspecto. En el trabajo de [Lim et al. \(2010\)](#) usaron un videojuego comercial donde crean a mano un **Behavior Tree** inicial cuyas operativas específicas se toman de forma aleatoria. Es entonces cuando se aplican los algoritmos genéticos sobre esta base del árbol, donde el *crossover* se realiza mediante el intercambio de subramas enteras con el mismo objetivo para dar origen a nuevos comportamientos y la mutación se realiza en parámetros de nodos específicos o insertando nuevas ramas de comportamientos generadas al azar. La función de *fitness* se entrenó mediante métricas específicas del videojuego, como el potencial defensivo y atacante del NPC. Este sistema logró mejorar a la IA del videojuego en un 55 % de las partidas, demostrando que los **Behavior Trees** generados resultaron ser correctos. Otros ejemplos del uso de la programación genética para la generación de **Behavior Trees** en el ámbito de la robótica la podemos encontrar en trabajos como [Iovino et al. \(2020b\)](#) o en [Iovino et al. \(2023\)](#), donde además los autores mezclan la programación genética con aprendizaje por demostración.

Finalmente nos encontramos con algoritmos de planificación para la generación de **Behavior Trees**, como podemos ver en el trabajo de [Colledanchise et al. \(2019\)](#). En este trabajo introducen una metodología para crear y modificar **Behavior Trees** en tiempo de ejecución mediante el algoritmo de planificación de retroencadenamiento (Backchaining) en el que se toman un conjunto de acciones con sus precondiciones y postcondiciones y las convierte en **Behavior Trees** atómicos bajo un nodo “Selector”. Una vez se procesan todas las acciones, se parte de un **Behavior Tree** que contiene las condiciones finales deseadas y, cada vez que el árbol devuelva un estado “Failure” porque el objetivo no se cumple, se reemplaza esa condición por uno de los **Behavior Trees** atómicos que sea capaz de resolverla, repitiendo iterativamente este proceso hasta que se de un **Behavior Tree** correcto. Si hay una violación de una precondición de otras partes ya predefinidas del árbol, el algoritmo detecta estas colisiones lógicas y las resuelve reordenando el **Behavior Tree** desplazando el subárbol conflictivo para incrementar su prioridad.

2.4. Generación de **Behavior Trees** mediante LLMs en la robótica

Dado el gran avance en el campo de los LLMs se pueden encontrar varios trabajos que se sirven de éstos para la creación automática de **Behavior Trees**, especialmente en el campo de la robótica.

Uno de los primeros trabajos en este ámbito es [Lykov y Tsetserukou \(2023\)](#), en el que los autores utilizan un modelo basado en Stanford Alpaca 7B al que realizan **Fine-tuning** mediante LoRA (modifican únicamente un grupo reducido de pesos de atención) con demostraciones generadas a través de otros modelos más grandes (text-davinci-003), consiguiendo generar **Behavior Trees** parecidos a los que podría crear un humano para comportamientos robóticos. Otros trabajos como [Izzo et al. \(2024\)](#) siguen una metodología similar en la que utilizan modelos ligeros (de 7B de

parámetros) en los que realizan Fine-tuning con datasets sintéticos. En el artículo [Ao et al. \(2025\)](#) estudia diferentes técnicas de In-Context Learning para generar Behavior Trees y, además, los compara con modelos de menor tamaño a los que se les ha aplicado Fine-tuning y los evalúa en simulaciones, consiguiendo una mayor tasa de aciertos el uso del In-Context Learning.

En el trabajo de [Li et al. \(2024\)](#) los autores proponen el desarrollo y entrenamiento de un LLM especializado únicamente en la generación de Behavior Trees. Para ello proponen un pipeline que consta de los siguientes pasos:

1. Creación de un dataset mediante la generación de datos sintéticos usando búsquedas en árbol de Monte Carlo (MCTS) combinadas con un sistema RAG.
2. Entrenamiento del modelo mediante aprendizaje auto-supervisado (MLM).
3. Fine-tuning supervisado con datos de instrucciones de usuarios con su respectivo Behavior Tree
4. Creación de un framework (BTGen Agent) para la generación de los árboles que consta de un módulo de memoria (almacena contextos a corto y largo plazo), módulo de acción (ontología de acciones disponibles), módulo de planificación y módulo de perfil (configura al LLM para que adapte roles específicos).
5. Creación de una metodología de verificación y validación (V&V) de las capacidades y el rendimiento del LLM.

Finalmente los autores del estudio [Merino-Fidalgo et al. \(2025\)](#) incorporan a su sistema de generación de Behavior Trees mediante ChatGPT un “intérprete de fallos”, el cual permite adaptar en tiempo de ejecución los árboles, consiguiendo una tasa de éxito del 89.6 %.

2.5. Generación de Behavior Trees mediante LLMs en videojuegos

A diferencia del campo de la robótica, la literatura sobre generación de Behavior Trees para videojuegos es escasa.

En el trabajo de [Paduraru et al. \(2025\)](#) los autores presentan un framework en el que, al igual que en trabajos previos del campo de la robótica, se pueden generar Behavior Trees a través del lenguaje natural. Para ello realizan un Fine-tuning al modelo “llama3.1:8B Instruct” mediante LoRA gracias a un corpus mixto de árboles generados manualmente sobre dos videojuegos comerciales y árboles generados mediante el modelo “GPT-4o”. Para generar los árboles se introducen las acciones disponibles en un almacén de vectores FAISS y se recuperan mediante etiquetado de roles semántico (SRL). Mediante pruebas con usuarios se vio que este agente generador alcanzó un 78 % de ejecución correcta en estructuras sencillas, y un 81 % de éxito en estructuras complejas gracias al post-procesamiento.

Para terminar, los autores de [ITO et al. \(2026\)](#) proponen un trabajo parecido mediante el modelo “GPT-5.2” siguiendo diferentes niveles de detallismo en el

prompt del diseñador, donde va desde la descripción explícita de la estructura del [Behavior Tree](#) buscado (en donde se consiguió un 100 % de precisión) hasta la delegación completa del diseño, pidiendo una descripción muy vaga del comportamiento buscado.

Esta escasez de trabajos en el ámbito de los videojuegos frente al campo de la robótica hace ver que es conveniente la investigación de esta línea.

Descripción del Trabajo

Debido al proceso tedioso y costoso (sobre todo en tiempo) que conlleva a los diseñadores la creación de árboles de comportamiento (BTs) de forma constante para diseñar a los diferentes personajes no jugador (NPCs), el objetivo general de este trabajo es la creación de una herramienta que sea capaz de generar BTs funcionales que sirvan de base para rebajar la carga de trabajo de los diseñadores. Para ello se busca un modelo que sea completamente opaco al usuario, que dé resultados en un tiempo inferior a la alternativa ya existente con una calidad similar y sea sencilla de usar sin requerir muchos conocimientos técnicos para, además, ayudar a diseñadores con un perfil no tan técnico a desarrollar con mayor facilidad.

Con esta idea en mente y gracias a los avances que se han producido en el campo de los modelos del lenguaje, se ha desarrollado un modelo de herramienta basada en generación mediante LLMs, ya que ofrece la ventaja de que los usuarios puedan explicar el comportamiento deseado en lenguaje natural. Como esta herramienta debería ser de fácil uso para los diseñadores y programadores, se propone un modelo en el que, sin salir de un proyecto de Unreal Engine, se puedan generar los BTs mediante su propia interfaz.

3.1. Diseño del modelo propuesto de la herramienta de generación de árboles de comportamiento




Figura 3.1: Diagrama donde se visualiza el flujo de la herramienta propuesta.

En la figura 3.1 se puede ver el flujo de la herramienta propuesta, donde el diseñador debe describir el comportamiento que busca para un NPC y, de forma opaca para éste, una serie de LLMs genera el BT con el comportamiento buscado, el cual deberá ser traducido a un formato JSON específico para poder ser contruido en Unreal Engine. Una vez creado el BT se devuelve el control a Unreal Engine, donde se ejecutará de forma automática para comprobar que es un BT válido tanto por cumplimiento de dependencias de tareas como por cumplimiento de un objetivo. En caso de ser así se termina la ejecución de la herramienta, pero en caso contrario se reinicia su ejecución, donde se le pasa al LLM el error del BT generado junto a las tareas ejecutadas en forma de contexto adicional y el resultado de la generación dada para arreglar el error.

En las siguientes secciones de este capítulo se explicará el entorno de pruebas desarrollado para este trabajo, así como la implementación de la generación de los BTs, la validación de éstos y las pruebas a usuarios realizadas.

3.2. Descripción del entorno

Lo primero que se ha necesitado en un entorno en el que se puedan implementar una serie de acciones y condicionales con el fin de tener la posibilidad de diseñar una serie de comportamientos para poder crear y ejecutar los BTs. Para ello y por el enfoque de este proyecto en el desarrollo de videojuegos, se han desarrollado una serie de escenarios en el motor de videojuegos Unreal Engine 5.7 debido también a

su amplio uso en la industria y su robusto sistema de BTs¹. Son estos entornos los que se van a comunicar con el agente LLM de Python para, posteriormente, probar los BTs generados y comprobar su validez.

Estos entornos, de los que se pueden ver un ejemplo en la figura 3.2, constan de un agente (el NPC que va a seguir el comportamiento buscado) cuyo controlador es una clase que hereda de la clase de Unreal Engine “AIController”, el cual contiene el componente de BT necesario para la futura ejecución de un BT. Además contiene un componente de Blackboard, el cual es esencial porque constituye la memoria del NPC. Este consiste en una serie de variables entrada/salida en las que las tareas y condicionales pueden leer y/o escribir, siendo esta la manera que tienen para interactuar con el entorno. En la misma figura se puede apreciar la interfaz en la que el usuario debe introducir la información necesaria para la generación del BT: la descripción del comportamiento buscado, el nombre del archivo con el que se va a guardar el BT generado, las entradas de la BB, el agente que va a ejecutar el BT generado y, opcionalmente, el nombre del archivo de validación del BT generado. Esta información la debe contener un Actor (los objetos del mundo de Unreal), llamado en la captura “BTGeneratorManager”, que tenga un componente llamado “BTGenerator”. Este componente de Actor es el encargado de lanzar el proceso de Python con la información que el usuario haya puesto, y el que comienza la ejecución de las pruebas del BT generado. Para comenzar la ejecución se debe pulsar el botón “GenerateBT” que se aprecia en la captura.




Figura 3.2: Captura de pantalla de uno de los entornos creados para el desarrollo de la herramienta.

3.2.1. Tareas y condicionales

Junto con el agente mencionado anteriormente se han preparado una serie de tareas (los cuales servirán como nodos terminales de los árboles) y condicionales que sirven como base para poder crear unos comportamientos de prueba. Estas tareas y condicionales son introducidos en una clase implementada mediante el patrón

¹Enlace a la documentación oficial de Unreal sobre los BTs: <https://dev.epicgames.com/documentation/unreal-engine/behavior-trees-in-unreal-engine>

Abstract Factory con el fin de simplificar la futura construcción de instancias de cada nodo. Para la construcción de los nodos mediante estas clases se precisa de la ID que identifiquen a la tarea o al condicional y una descripción de lo que hace, la cual será fundamental para el contexto del LLM. En esta descripción y para las clases que requieran una variable de la Blackboard es recomendable introducir qué tipo de variable se requiere para que el modelo LLM sea más preciso.

Para registrar una nueva clase en esta factoría se debe llamar a las funciones “RegisterTask”, “RegisterBlackboardTask” o “RegisterDecorator”, las cuales son funciones template en las que se les debe poner la clase que se desea ser introducida y pasar como argumentos el ID que se desee poner y la descripción de lo que realiza la tarea o lo que revisa el condicional.

Las tareas, junto con sus descripciones en español (en el trabajo realizado las descripciones han sido escritas en inglés para respetar el idioma del prompt) que se han creado para estas pruebas son las siguientes:

- **RotateToFaceBBEntry**: Rotar hasta encarar objetivo. El objetivo tiene que ser de tipo “Objeto”.
- **ChasePlayer**: Perseguir al jugador.
- **MoveTo**: Mover a la posición u objeto de destino. La variable objetivo tiene que ser de tipo “Objeto” o “Vector3”
- **FindRandomPatrol**: Elegir un punto aleatorio del mapa y guardarlo como objetivo.
- **Wait**: No hacer nada.
- **PickRedFlower**: Coger una flor roja.
- **PickBlueFlower**: Coger una flor azul.
- **PickYellowFlower**: Coger una flor amarilla.
- **PickBlackFlower**: Coger una flor negra.
- **ChooseRedFlower**: Elegir una flor roja como objetivo.
- **ChooseBlueFlower**: Elegir una flor azul como objetivo.
- **ChooseYellowFlower**: Elegir una flor amarilla como objetivo.
- **ChooseBlackFlower**: Elegir una flor negra como objetivo.
- **Attack**: Atacar si hay algún objetivo cerca.
- **SelectWaypoint**: Elegir un punto de ruta aleatorio y establecerlo como objetivo. El objetivo debe ser de tipo “Objeto”

Los condicionales implementados, junto con sus descripciones en español (al igual que las tareas, las descripciones en el trabajo están en inglés), son los siguientes:

- **HasLineOfSight?**: Cierto si el jugador está en línea de visión, falso si no. La variable que verifica tiene que ser de tipo “Bool”
- **IsItNear?**: Cierto si la distancia entre el ejecutor y el jugador es menor o igual que un umbral prefijado, falso en caso contrario. El objetivo tiene que ser de tipo “Objeto”.

Aunque el número de acciones y decoradores disponibles en esta implementación es reducido, pero sirve como sistema de prueba para la generación y la propuesta de evaluación.

3.2.2. Formato del árbol de comportamiento generado

Para la generación del BT se ha decidido que el formato que debe devolver la herramienta generada sea un archivo JSON debido a su facilidad para leerlo, tanto por un humano como por un programa. Para la futura traducción del JSON a un BT de Unreal ha sido necesaria la estandarización del formato del JSON. Para ello se ha hecho uso del JSON Schema Draft 2020-12², el cual es un lenguaje declarativo que sirve para definir una estructura de datos en formato JSON para que pueda ser considerada válida.

Este JSON Schema consta de dos partes: la Blackboard y el BT. La Blackboard es una lista de objetos JSON que contienen solo un par clave-valor, donde la clave es el nombre de la variable y el valor es el tipo de la variable (Bool, Int, Float, Vector, Object o String). El BT consta de un nodo (la raíz) que debe contener el tipo de nodo (Task, Sequence, Selector o Parallel), una lista de decoradores (en el caso de no tener se debe quedar vacía), la cual consiste en objetos JSON que debe contener como clave el nombre del decorador y como valor la variable de la Blackboard que va a usar, y una lista de nodos hijos. Estos nodos hijos siguen la misma estructura que la raíz. Como propiedades adicionales, puede contener una lista de nombres de variables de la Blackboard que vaya a necesitar, y, en el caso de ser una tarea, debe tener el ID de ésta. Este esquema se puede encontrar en el apéndice A

Para cuando el modelo haya generado el JSON con el [Behavior Tree](#), la clase “BTGeneratorComponent” entra en el modo de juego. Es en este momento donde el NPC, desde su función “BeginPlay” (función de Unreal que es llamada cuando se inicia el juego), coge el nombre del archivo JSON generado para traducirlo a la lógica de Unreal. Esta traducción la hace la clase “BTConstructor”, la cual es una clase que sigue el patrón [Singleton](#) con el fin de que pueda ser accedida desde cualquier clase del juego. Esta clase crea un BT (clase “BehaviorTree”) y una Blackboard (clase “BlackboardData”) que serán rellenados con la información del JSON. Para ello, la clase rellena primero la Blackboard creando las variables disponibles en el JSON. Finalmente se crea el BT mediante un método recursivo que recorre y genera el árbol en profundidad, creando primero todos los nodos hijos de una rama antes de pasar a sus hermanas.

Una vez se ha especificado todo lo necesario para la generación de los BTs se ha procedido a la conexión con la herramienta que los genera. Como se ha mencionado

²documentación del JSON Schema Draft 2020-12: <https://json-schema.org/draft/2020-12>

en la sección 3.1, por comodidad del usuario es el propio entorno quien lanza el proceso de Python, haciendo de la generación un modelo de caja negra para el usuario. Para ello se lanza el proceso Python con el archivo principal de la herramienta y se le pasan como argumentos la ruta del script de la herramienta, las listas de tareas (la lista de tareas que requieren de una variable de la Blackboard y la lista de las que no), la lista de decoradores, el comportamiento buscado y la lista de entradas de la Blackboard.

3.3. Generación de los Behavior Trees

3.3.1. Generación de forma directa

En un principio se planteó la generación de los BTs de forma directa, en la que se le pasaba el prompt del usuario a un modelo local y éste generaba un BT en el formato JSON especificado en el apéndice A. Este planteamiento se realizaba mediante el módulo de Python “guidance”, el cual permite forzar un formato de salida a un modelo de Ollama³, el cual es un gestor y motor de ejecución de LLMs. Para este caso se probaron diferentes modelos, todos probados bajo el mismo escenario y con la temperatura en 0.0:

- **Prompt:** NPC that, constantly, select a random point from the map, goes to the point and waits a time.
- **Acciones disponibles:** ChooseRandomPoint, MoveTo, WaitTime, RotateToFaceBBEntry.
- **Variables de la Blackboard:** Point (Vector3)

Se buscó una tarea sencilla para establecer un baseline de los modelos. Los modelos probados para este planteamiento, con sus parámetros, su tiempo de ejecución y su resultado se pueden ver en la tabla 3.1:

Tabla 3.1: Modelos probados para la generación directa del JSON mediante guidance.

Modelo	Parámetros	Tiempo de ejecución
microsoft/Phi-4-mini-instruct	4B	~10 segundos
qwen2.5:7b	7B	~20 segundos
Qwen/Qwen2.5-Coder-7B-Instruct	7B	~30 minutos
llama3.1:8b	8B	~2 horas
deepseek-r1:8b	8B	>2 horas

Los modelos de menor tamaño no generaban buenos BTs para una tarea tan sencilla (como tareas que faltaban o variables de la Blackboard mal asignadas).

³documentación oficial de Ollama: <https://ollama.com/>

Sin embargo, los modelos grandes si conseguían generar BTs que cumplieran con la función que se les pedía, aunque añadiendo más tareas de las necesarias. Pero, como se puede observar en la tabla, para conseguir esos BTs la ejecución podía tardar horas, por lo que también debían ser descartados. Tanto la malfuncionalidad de los modelos pequeños como la tardanza de los modelos grandes se puede explicar por el funcionamiento de guidance y la complejidad recursiva del JSON Schema empleado, por lo que esta primera generación debería ser descartada.

3.3.2. Generación mediante fragmentación por subtareas

En base a otros trabajos relacionados como [Hoffmeister et al. \(2026\)](#) o [Choi et al. \(2026\)](#) se replanteó la generación para dividirlo en subtareas con el fin de simplificar la tarea al LLM. Para ello se encargaban cuatro agentes LLM, cada uno con un rol distinto. El primero se encargaba de dividir la acción mandada por el usuario mediante el prompt en subtareas. En el ejemplo de un NPC que tiene que buscar al jugador para perseguirlo y atacarlo cuando esté cerca, este primer agente debería dividir la tarea principal en:

1. Buscar al jugador
2. Perseguir al jugador
3. Comprobar la distancia del NPC al jugador
4. Atacar al jugador

Una vez están separadas las tareas en subtareas, un segundo agente selecciona para cada subtarea el subconjunto de las acciones necesarias para realizar esta subtarea. Estas acciones que selecciona se guardan en una lista directamente en el formato JSON especificado por el JSON Schema. Cuando ya se ha seleccionado el subconjunto un tercer agente decide qué tipo de nodo padre van a tener los subconjuntos (Selector, Sequence o Parallel). Finalmente un último agente revisa los decoradores y las tareas que requieran de una variable de la Blackboard para adjudicársela. Se puede ver un diagrama de flujo de esta generación en la figura [3.3](#).




Figura 3.3: Diagrama de flujo de la generación de BTs mediante división en subtareas

Finalmente se descartó esta opción debido a que los árboles resultantes quedaban muy planos (con menos niveles de profundidad de lo que se cabía esperar), haciéndolos difícilmente legibles y modificables. Además los agentes tendían a equivocarse (mala división en subtareas, confusión entre el tipo que debería ser un nodo padre) o a alucinar (inventarse tareas o decoradores que no existen), no consiguiendo de este modo un [Behavior Tree](#) válido con ninguno de los modelos probados.

3.3.3. Generación mediante pseudocódigo

Trabajos como [Ahn et al. \(2022\)](#) o [Song et al. \(2023\)](#) muestran que, dado un conjunto de acciones posibles a realizar, los LLMs son capaces de seleccionar de éstas un orden para realizar una tarea de alto nivel. Es por ésto que se decidió que el LLM generase esta secuencia en un formato de pseudocódigo que fuese fácilmente convertible al formato JSON deseado. Este pseudocódigo se especifica de la siguiente manera:

- Las palabras reservadas son: SEQUENCE, SELECTOR, PARALLEL, IF, THEN, ELSE, DO, END.
- Los bloques de nodos compuestos (como SELECTOR) deben acabar con la palabra END.

- Las condiciones deberán ser escritas como “IF (nombre del condicional de la lista de decoradores) THEN”.
- Los condicionales serán usados por el nodo siguiente.
- Las acciones deberán ser escritas como “DO (nombre de la acción de la lista de acciones)”.

Se puede ver un ejemplo de este pseudocódigo en la figura 3.4.

```
SELECTOR
  IF has_key THEN
    SEQUENCE
      DO move_to_door
      DO open_door
    END
  ELSE
    SEQUENCE
      DO find_key
      DO move_to_door
      DO open_door
    END
  END
END
```

Figura 3.4: Ejemplo del pseudocódigo que el LLM debe generar.

Como se ha podido ver en trabajos relacionados, la generación de BTs mediante LLMs mejora considerablemente en modelos a los que se le ha aplicado [Fine-tuning](#) o se les proporciona ejemplos. Debido a la falta de capacidad computacional no se ha podido hacer un Fine-tuning de un LLM, por lo que se ha optado a recopilar una pila de ejemplos de BTs para poder hacer un sistema [RAG](#). El RAG es una técnica de inteligencia artificial que consiste en conectar un LLM con una base de datos externa a sus conocimientos disponibles que puede consultar para ampliar su contexto mediante búsquedas de conceptos próximos en el espacio vectorial (generalmente utilizando la distancia coseno de dos vectores como métrica) al prompt dado, posibilitando así las alucinaciones.

Para ello se ha escogido el dataset publicado por [Lykov y Tsetserukou \(2023\)](#)⁴, el cual contiene 8366 ejemplos de BTs. Debido a que estos BTs están en formato XML no se pueden utilizar de forma predeterminada para el sistema RAG, por lo que se ha procedido a hacer un preprocesamiento de los datos.

Este preprocesado carga el dataset desde Hugging Face (plataforma de código abierto donde los usuarios pueden subir modelos o datasets, similar a otras como Kaggle), los limpia y los traduce al formato necesario. La limpieza consiste en el uso de expresiones regulares para poder subsanar los fallos de formato más comunes que tenían estos datos, como diferencias entre nombres por mayúsculas y minúsculas,

⁴Enlace a la página de Hugging Face: https://huggingface.co/datasets/ArtemLykov/LLM_BRAIn_dataset

etiquetas sin la apertura o la clausura, faltas de comillas, etc. Si hay algún ejemplo que, aun con la limpieza, no se ha conseguido parsear por otro fallo, se descarta. Finalmente, de los 8366 ejemplos se quedaron 8290 BTs válidos.

Una vez los datos están limpios, se procede a la traducción del formato XML gracias al módulo “xml.etree.ElementTree”, el cual es un módulo de Python que sirve para trabajar con datos que estén en formato XML. Cuando el árbol ha sido construido se guarda en formato JSON siguiendo el JSON Schema especificado para este trabajo, y finalmente se traduce al pseudocódigo especificado previamente gracias a otra función recursiva, quedando así 8366 archivos JSON con el prompt de la acción de alto nivel a realizar, el BT resultante y el pseudocódigo.

Con los ejemplos de BTs preparados se ha procedido a la aplicación del sistema RAG. Al iniciar la herramienta de generación se crea el [Almacén vectorial](#) cargando los documentos mencionados anteriormente en estructuras llamadas “Document”, provenientes del módulo “langchain_core.documents”. Una vez están todos los documentos cargados se procede a hacer el [Embedding](#) de éstos de manera local gracias al modelo de Hugging Face “all-MiniLM-L6-v2” mediante el módulo “langchain_huggingface”. Estos [Embeddings](#) se crean y se almacenan en una estructura de tipo [FAISS](#) gracias al módulo “langchain_community.vectorstores”. Una vez creado el almacén vectorial se rescatan las 5 búsquedas más similares al comportamiento pedido por el usuario y se incluyen en el prompt del sistema del LLM.

Para la generación de pseudocódigo a partir del comportamiento buscado se ha requerido un modelo de mayor tamaño que los previamente usados, por lo que se ha usado el LLM “Mistral Large 3”, el cual cuenta con un total de 675B de parámetros (41B de ellos son parámetros activos, los que actúan por cada token), mediante el módulo “langchain_mistralai”, el cual realiza llamadas de [API](#) al modelo. Para el prompt de sistema del modelo se han realizado varias técnicas de *prompt engineering* con el fin de reducir las alucinaciones en la generación del pseudocódigo:

- **Role prompting:** Se le especifica al LLM como debe actuar: “You are an expert in behavior trees and algorithm design.”.
- **Especificación de la tarea:** Se le especifica para qué tarea debe responder: “Your task is to convert a high-level task description into a structured pseudocode algorithm that can later be transformed into a Behavior Tree.”.
- **Few-shot prompting:** Se le especifican varios ejemplos, sacados del sistema RAG mencionado anteriormente.
- **Chain-of-Thought:** Obliga al modelo a, internamente, seguir la línea de pensamiento representada en la figura [3.5](#)
- **Self-Critique Prompting:** Le pide al modelo que evalúe su respuesta buscando si se ha inventado acciones o condicionales. Esto se hace en una segunda llamada con el siguiente prompt: “Verify if your pseudocode is made only with the actions and conditions available. Responde me with ONLY the final pseudocode and no explanations or plain text”




Figura 3.5: Diagrama de la cadena de pensamiento que sigue el LLM generador de pseudocódigo.

El prompt de sistema completo se puede ver en el apéndice B.

Una vez se ha generado el pseudocódigo se procede a la traducción de éste al formato JSON. Esto se hace mediante la clase “BehaviorTreeParser” y mediante dos clases auxiliares: Composite y Action, las cuales ambas heredan de la clase Node. La clase Composite contiene el tipo (un string), una lista de nodos hijos (lista de tipo “Node”), un decorador (opcional de tipo string), las variables de la Blackboard del decorador (una lista de strings) y un identificador (un entero). La clase Action tiene el nombre de la tarea (un string), las variables de la Blackboard que puede usar la tarea (una lista de strings), un decorador (opcional de tipo string), las variables de la Blackboard del decorador (una lista de strings) y un identificador (un entero). Para la traducción del pseudocódigo primero se preprocesa guardando cada línea en una lista de strings. Seguido de esto se procesa cada línea dividiendo cada palabra de ésta y actuando dependiendo de cuál es su primera palabra:

- **SEQUENCE, SELECTOR o PARALLEL:** Se crea un nodo de tipo “Composite”, se establece su tipo como la palabra usada y se verifica si hay una condición pendiente. Si es el caso, se establece esta condición. Además, se añade este nodo a su padre (en el caso de haberlo es el último nodo añadido a una pila auxiliar) y se añade a la pila auxiliar.
- **IF:** Se verifica si tiene un condicional o si el condicional que tiene existe. En caso contrario de cualquiera de los dos se lanza un “ParserError” indicando la línea y el fallo. En el caso de que no haya error se establece la condición como la condición pendiente.
- **DO:** Se verifica si tiene una acción o si esa acción existe. Al igual que en el caso anterior, de no ser así se lanza un “ParserError”. En caso de haberlo se crea un nodo de tipo “Action” con el nombre de la acción que hay a continuación. Igualmente que con los nodos compuestos, se verifica si hay alguna condición pendiente y se añade el nodo al padre.
- **END:** Se verifica que la pila no esté vacía. En caso contrario significa que hay un “END” sin bloque que cierre, por lo que se lanza un “ParserError”. En caso de que sí esté vacía se saca un nodo de la pila. A continuación se verifica si la pila se ha quedado vacía, lo que significaría que ese nodo era la raíz del árbol. En caso de ya haber raíz se lanza un “ParserError” indicando que hay múltiples raíces.

Una vez se acaba este procesamiento de cada línea se verifica si sigue habiendo pila (lo que indicaría que hay bloques sin cerrar) o si no se ha generado una raíz. Los posibles “ParserError” lanzados durante este proceso se recogen fuera de esta función para poder volver llamar al LLM indicando el error de la excepción con el fin de que devuelva un pseudocódigo arreglado.

Cuando ya ha sido procesado todo el pseudocódigo se crea una clase auxiliar llamada “BlackboardAssignmentAgent” que se encarga de asignar las variables de la Blackboard a las tareas o los decoradores. Para ello reconstruye el pseudocódigo asignándole el identificador a cada nodo (este identificador es el orden de aparición de cada acción o decorador, ya que en los BT es normal que se repitan) y se le pide a un segundo LLM que a cada decorador y acción que necesite una variable de la Blackboard se le asigne. Por problemas con sobrecarga de peticiones de la API, para este caso se usa un modelo local más pequeño, el modelo “llama3:8b”. Para el prompt de sistema de este LLM se le pasa el árbol en el formato del pseudocódigo reconstruido mencionado anteriormente, la lista de las acciones que necesitan una variable de la Blackboard con sus descripciones y la lista de variables de ésta. Para disminuir las alucinaciones de este LLM se han usado las siguientes técnicas de *prompt engineering*:

- **Role prompting:** “You are an expert in Unreal Engine Behavior Trees.”
- **Especificación de la tarea:** “Your task is NOT to understand the whole game. Your ONLY task is assigning Blackboard variables to Behavior Tree nodes.”
- **One-shot prompting:** Se le especifica un ejemplo inventado mostrado en la figura 3.6

Una vez genera la respuesta se valida el resultado comprobando si todos los nombres (variables y acciones) son correctos. Si hay algún nombre que no existe porque el modelo ha alucinado se le pide al modelo que lo reintente. Cuando el resultado es válido se guardan las variables asignadas en los nodos correspondientes y, finalmente, se construye el JSON mediante una función recursiva desde la raíz del árbol y se guarda en un archivo con el nombre especificado por el usuario.

Trabajos como [Valmeekam et al. \(2023\)](#) han demostrado que la planificación generada por LLMs como se ha hecho en este trabajo no resultan ser fiables de forma exacta, por lo que se ha diseñado un sistema de validación y corrección de errores automático.

3.4. Validación automática de los Behavior Trees

Para que los Behavior Trees generados se considerasen válidos para las pruebas se han tenido en cuenta dos factores: que los árboles generados respeten el orden de los nodos (si hay acciones dependientes unas con otras no deben ejecutarse los hijos antes que los padres) y que deben cumplir un objetivo. Estas comprobaciones no son obligatorias para el funcionamiento de la herramienta, sino que es un apoyo para automatizar este proceso.

```
Example Input:
Actions : grab_key : Stores the key in the inventory,
        move_to : Moves to a position,
        open_door: Open a door
Variables: ["Key" : "Object", "Door" : "Object", "Enemy_position" : "Vector3"]
Tree:
SEQUENCE
  DO move_to#1
  DO grab_key#1
  DO move_to#2
  DO open_door#1 [Decorator=IsNear?#1]
  DO wave#1

Output format:
{
  "Actions": {
    "move_to#1": ["Key"],
    "grab_key#1": ["Key"],
    "move_to#2": ["Door"],
    "open_door#1": ["Door"]
  },

  "Decorators": {
    "IsNear?#1": ["Door"]
  }
}
```

Figura 3.6: Ejemplo del input y el output del LLM que establece las variables de la Blackboard.

3.4.1. Validación de dependencias

Para comprobar el orden correcto de los nodos se ha recurrido al uso de un autómata finito no determinista, NFA por las siglas en inglés de Non-Deterministic Finite Automata ([Park et al. \(2004\)](#), [Camacho et al. \(2017\)](#)), definido de la siguiente manera:

- Los estados son los nodos de [Behavior Tree](#).
- Las transiciones son las relaciones padre-hijo.
- El alfabeto son las IDs de las tareas.
- Hay un conjunto de estados abiertos.
- Hay una serie de estados iniciales.
- La función de transición es no determinista porque un mismo símbolo puede activar múltiples nodos de forma simultánea, ya que diferentes tareas pueden estar en diferentes puntos del árbol.

Este NFA está implementado en la clase “BehaviorList”, la cual está implementada mediante el patrón Singleton para que todas las tareas puedan acceder a ella. Para esta verificación se necesita un archivo JSON en el que se especifican las restricciones. Se puede ver un ejemplo de un JSON con las restricciones en el apéndice [C](#).

Una vez se construyan las dependencias mediante el NFA empieza la ejecución del BT. Para que funcione esta comprobación a la hora de ejecutarse una tarea o un decorador, éste debe llamar a la función “addBehavior” de esta clase con el nombre de la tarea. Cuando llega una tarea nueva se realiza la comprobación de las dependencias de la siguiente forma:

1. Se recuperan los nodos candidatos gracias a su ID.
2. Se crea un nuevo conjunto de nuevos estados.
3. Si un candidato no tiene padre (no depende de ninguna otra acción) se añade este nodo a los nuevos posibles estados.
4. Se recorren todos los hijos de los estados activos y se comprueba si coinciden con el ID de la tarea o el decorador actual. En caso afirmativo se añade este hijo al conjunto de nuevos estados.

Al final de la función se comprueba si el conjunto de nuevos estados está vacío. En el caso de que el conjunto de nuevos estados no está vacío implica que sí se han respetado las dependencias, por lo que éste pasa a ser el conjunto de estados abiertos. Por el otro lado, si el conjunto de nuevos estados está vacío es que no existe ningún posible estado en el que el orden de la ejecución de los nodos sea la actual, lo que implica que no se han respetado las dependencias y la validación falla.

Para los casos en los que la validación puede fallar se ha creado una clase interfaz “IValidatorCallback” que se encarga de gestionar las terminaciones de la validación

por fallos o por terminación de la ejecución. Ya que es la clase “GeneratorComponent” quien se encarga de llamar a la herramienta de generación, es esta quien hereda de la interfaz y quien es llamada por la clase “BehaviorList” cuando falla la validación, pasándole una lista de todas las acciones ejecutadas hasta el momento y la acción en la que ha fallado. Es entonces cuando la clase “GeneratorComponent” interrumpe el modo de juego y vuelve a llamar a la herramienta con el pseudocódigo fallido, el contexto dado por “BehaviorList” y el prompt con la acción original y vuelve a intentar la ejecución cuando la herramienta arregla el pseudocódigo.

3.4.2. Validación de objetivos

Para validar los objetivos específicos de los comportamientos se ha creado una clase interfaz “ObjectiveValidatorBase” que contiene un método para comprobar si el objetivo se ha cumplido y un mensaje de error indicando que el objetivo ha fallado. De esta interfaz deben heredar componentes de Actor para que los objetos “BTGeneratorManager” los puedan tener y puedan hacer la comprobación de los objetivos una vez se acabe la ejecución. Si la comprobación del objetivo es fallida se le pasa a la herramienta el mensaje de error y la lista de tareas ejecutadas, así como el pseudocódigo fallido y el prompt original, y se vuelve a intentar con un pseudocódigo arreglado.

3.4.3. Entornos creados para la validación

Una vez se han tenido los métodos de validación de los BTs se han creado tres entornos con diferentes pruebas.

El primero de ellos consta de tres flores de distintos colores: rojo, azul y amarillo. En este entorno se le pide a la herramienta que genere un BT donde recoja una única flor de cada tipo, independientemente del orden, con el siguiente prompt: “NPC that has to choose and pick one flower red, one flower yellow, and one flower blue. In order to pick a flower it has to be first in the position of the flower.”. Al ser una tarea sencilla la herramienta solo ha necesitado un intento y un tiempo de ejecución de 84.84 segundos para crear un BT válido y que cumpla con el objetivo.

El segundo de los entornos consta de tres flores azules, una flor roja y una flor amarilla, y aquí se le pide a la herramienta que genere un BT que recoja tres flores azules y después una roja mediante el siguiente prompt: “NPC that has to choose and then pick first three blue flowers, and, after that, has to choose and pick one red flower. In order to pick a flower it has to be first in the position of the flower”. Al igual que en el caso anterior, solo ha necesitado de un intento y un tiempo de 45.46 segundos para realizar un BT válido. En la figura 3.7 se puede ver una captura de pantalla de este entorno.




Figura 3.7: Captura de pantalla del segundo entorno de pruebas de validación.

El tercer entorno consta de un enemigo y un punto de patrulla. Aquí se le pide a la herramienta que genere un comportamiento clásico en videojuegos: un NPC que patrulle el escenario por distintos puntos y, que si ve al jugador, le persiga para atacarle. Para ello se ha usado el siguiente prompt: “NPC that has to do one of this two options: - If the objective is at his line of sight it has to: 1. chase him 2. move to his position 3. if is near the objective, it has to attack him. - Otherwise, it has to: 1. select a waypoint 2. move to the waypoint”.

A pesar de ser una petición más compleja debido a la naturaleza del comportamiento y al aumento de número de variables de la Blackboard (cuatro variables, dos condicionales para ver si el objetivo está en el punto de mira y si el objetivo está cerca, el punto de patrulla a elegir y el objetivo a perseguir), la herramienta ha sido capaz de generar en 153.1 segundos un BT válido a la primera en cuanto a cumplimiento de objetivos y respetando las dependencias, aunque sí se ha tenido que modificar alguna tarea que requería de una variable de la Blackboard que el segundo LLM no le ha adjudicado ninguna variable. En la figura 3.8 se puede ver una captura de pantalla de este tercer entorno.




Figura 3.8: Captura de pantalla del tercer entorno de pruebas de validación.

Con los resultados de esta validación, resumidos en la tabla 3.2, se ha podido establecer un baseline del funcionamiento de la herramienta para, finalmente, realizar pruebas con usuarios.

Tabla 3.2: Resultados de las pruebas de validación

Entorno	Intentos	Tiempo de ejecución
1	1	84.84 segundos
2	1	45.46 segundos
3	1	153.1 segundos

Pruebas con usuarios

Como se ha mencionado en la sección 1.2, lo que se busca en este trabajo es una herramienta capaz de generar de manera similar a los humanos un BT funcional o, al menos, una aproximación que sea capaz de disminuir el trabajo a los diseñadores de videojuegos. Con este objetivo en mente se ha diseñado unas pruebas con usuarios para comprobar si se cumplen los objetivos planteados.

Para ello se ha realizado un plan de pruebas donde se evalúan los tiempos de ejecución de generación y ejecución de los BTs, la comparación entre los tiempos de un BT generado por un humano y uno generado por la herramienta, los intentos de generación de un BT y la calidad de la herramienta en cuanto a usabilidad y funcionalidad. Para estas métricas las hipótesis iniciales eran las siguientes:

- H1: La herramienta es capaz de generar BTs más rápido que un diseñador que los hace a mano
- H2: Los BTs generados realizan una ejecución similar a los realizados por un humano
- H3: La calidad de los BTs generados por la herramienta es un poco menor que los generados por un humano, pero les permite a los diseñadores tener un punto de partida más rápido que puede ser fácilmente modificable, disminuyendo así el tiempo de trabajo
- H4: La herramienta de generación de BTs es intuitiva y fácilmente de utilizar.

Para poder comprobar estas hipótesis se han buscado usuarios que cumplan con el perfil de un diseñador de videojuegos que haya trabajado con Unreal Engine y sus BTs. El procedimiento con los usuarios ha sido el siguiente:

1. Con el fin de mantener el anonimato, se le asigna un identificador único a cada usuario.
2. Se le pide que haga un BT de un NPC que patrulla hasta que vea un objetivo, que debe perseguirlo hasta estar lo suficientemente cerca como para atacarlo.
3. Se le pide que haga un BT de un NPC que va recogiendo flores hasta que vea un objetivo, que en ese caso debe huir a un punto del mapa.

4. Se les cronometra desde el momento en el que se les indique que pueden empezar hasta que consigan una ejecución que satisfaga a los objetivos propuestos.
5. Se les pide que realicen los mismos BTs con la herramienta.
6. Se les pide que rellenen un formulario sobre la usabilidad y calidad de la herramienta.

Para cada BT que debería ser creado se hicieron dos escenarios distintos, uno en el que se deba usar la herramienta y otro en la que el NPC ejecuta un BT creado a mano. Para el primer BT se ha hecho una copia del tercer escenario mencionado en la sección 3.4, con un objetivo y un punto de patrulla cerca de él en el mapa. El segundo escenario consta de un objetivo, dos flores rojas (una de ellas en frente el objetivo para que el NPC tenga que pasar por delante de él) y un punto de patrulla alejado del objetivo.

El formulario, que se puede encontrar en el apéndice D, mide la usabilidad y la calidad de la herramienta frente a BTs creados por un humano. Para la usabilidad se ha decidido evaluar mediante el System Usability Scale (SUS), introducido en Brooke (1996), que consiste en un cuestionario estandarizado de 10 items que siguen la escala de Likert de 5 puntos, que van desde “Totalmente en desacuerdo” a “Totalmente de acuerdo”. Este método de evaluación se ha decidido seguir por evidencias de su robustez en estudios como Bangor et al. (2008) o Peres et al. (2013).

Para la calidad de la herramienta se les han realizado preguntas sobre los resultados esperados de tiempos de ejecución, diferencias entre la calidad y similitud de sus BTs y los generados por la herramienta, y su funcionalidad como punto de partida. Finalmente se ha habilitado un campo de texto no obligatorio de respuestas libres donde los usuarios podrían expresar su opinión sobre los BTs generados y la herramienta.

Debido al perfil específico que se necesitaban para las pruebas solo se han podido realizar pruebas con 3 usuarios, por lo que las conclusiones sirven como una aproximación pero no se deben tomar como concluyentes.

En cuanto a la usabilidad podemos ver los resultados individuales en la tabla 5.1 y en la figura 5.1 que se ha obtenido una media de 90.83 sobre 100 con una desviación estándar de 15.88, lo cual supera con creces la media de 68 establecida por el artículos como Hyzy et al. (2022), por lo que dadas estas pruebas se puede decir que la herramienta cumple con el objetivo de accesibilidad, haciéndola así fácil de utilizar y confirmando con los datos dados H4.

Tabla 4.1: Resultados de la encuesta SUS

Usuario	Puntuación
U1	72.5
U2	100
U3	100




Figura 4.1: Resultados de la encuesta SUS de los usuarios sobre la usabilidad de la herramienta.

La comparativa de los tiempos podemos verla en la tabla 5.2 y en la figura 5.2, en donde a excepción del primer BT que ha tardado más en generarlo la herramienta que el segundo usuario, hay una diferencia significativa en cuanto a la tardanza, beneficiando a los generados por la herramienta. Además, como podemos ver en la figura 5.3, los usuarios tienen una opinión favorable sobre los tiempos de ejecución de la herramienta con una media del 86.6 %, afirmando así la hipótesis inicial de generar de forma más rápida los BTs con unos tiempos de generación adecuados (H1).

Tabla 4.2: Tiempo (en segundos) de generación de cada BT por cada usuario

Usuario	BT 1 manual	BT 1 herramienta	BT 2 manual	BT 2 herramienta
U1	578	238	332	142
U2	315	486	159	35
U3	271	35	174	37




Figura 4.2: Comparación de cuánto han tardado en crear los usuarios los BTs junto a cuánto ha tardado la herramienta.




Figura 4.3: Opinión de los usuarios sobre los tiempos de ejecución de la herramienta del 1 al 5, siendo 1 una opinión desfavorable y 5 la más favorable.

Siguiendo con la calidad de los BTs podemos observar en las figuras 5.4 y 5.5 que la calidad de los BTs es inferior a los generados por un humano (con una media en las respuestas del 80 %), pero que cumplen con la ejecución esperada (con una media de las respuestas del 80 % también). Esto se puede explicar gracias a las respuestas de las preguntas sobre si los BTs generados tenían más nodos de los necesarios y si eran distintos a los generados por los humanos, en los que todos los usuarios respondieron que la herramienta añadía algunos nodos extra (tanto compuestos como tareas innecesarias) y que esto hacía que los BTs generados fuesen distintos a los creados manualmente, dando una calidad inferior pero con una ejecución similar, confirmando así la hipótesis H2.




Figura 4.4: Respuestas de los usuarios sobre la calidad de los BTs generados por la herramienta, donde 1 es que no están de acuerdo con la afirmación de que la calidad de los BTs generados por la herramienta son inferiores y 5 es que están completamente de acuerdo.




Figura 4.5: Respuestas de los usuarios sobre la ejecución esperada de los BTs, donde 1 es que consideran una mala ejecución y 5 significa una ejecución correcta.

Finalmente y junto a los resultados del apartado de calidad, la comprobación de

H3 se puede apoyar en los resultados de las figuras 5.6, 5.7 y 5.8, donde podemos ver que los usuarios han tenido una buena opinión sobre la idea de la usabilidad de la herramienta como apoyo para los diseñadores, respondiendo con un 93.4 % a la opinión de que sirve como buen punto de partida y que, gracias a la facilidad de modificación de los JSONs generados (con una media de respuestas del 86.6 %), la herramienta puede servir para disminuir la carga de trabajo de los diseñadores (con una opinión del de media 93.4 %).




Figura 4.6: Respuestas de los usuarios donde indican si los BTs generados sirven como punto de partida (5) o no (1)




Figura 4.7: Respuestas de los usuarios sobre la facilidad para modificar los BTs generados, donde 1 es significa que es difícil y 5 significa que es fácil.




Figura 4.8: Respuestas de los usuarios sobre su opinión de si la herramienta puede disminuir (5) o no (1) la carga de trabajo de los diseñadores.

Pruebas con usuarios

Como se ha mencionado en la sección 1.2, lo que se busca en este trabajo es una herramienta capaz de generar de manera similar a los humanos un BT funcional o, al menos, una aproximación que sea capaz de disminuir el trabajo a los diseñadores de videojuegos. Con este objetivo en mente se ha diseñado unas pruebas con usuarios para comprobar si se cumplen los objetivos planteados.

Para ello se ha realizado un plan de pruebas donde se evalúan los tiempos de ejecución de generación y ejecución de los BTs, la comparación entre los tiempos de un BT generado por un humano y uno generado por la herramienta, los intentos de generación de un BT y la calidad de la herramienta en cuanto a usabilidad y funcionalidad. Para estas métricas las hipótesis iniciales eran las siguientes:

- H1: La herramienta es capaz de generar BTs más rápido que un diseñador que los hace a mano
- H2: Los BTs generados realizan una ejecución similar a los realizados por un humano
- H3: La calidad de los BTs generados por la herramienta es un poco menor que los generados por un humano, pero les permite a los diseñadores tener un punto de partida más rápido que puede ser fácilmente modificable, disminuyendo así el tiempo de trabajo
- H4: La herramienta de generación de BTs es intuitiva y fácilmente de utilizar.

Para poder comprobar estas hipótesis se han buscado usuarios que cumplan con el perfil de un diseñador de videojuegos que haya trabajado con Unreal Engine y sus BTs. El procedimiento con los usuarios ha sido el siguiente:

1. Con el fin de mantener el anonimato, se le asigna un identificador único a cada usuario.
2. Se le pide que haga un BT de un NPC que patrulla hasta que vea un objetivo, que debe perseguirlo hasta estar lo suficientemente cerca como para atacarlo.
3. Se le pide que haga un BT de un NPC que va recogiendo flores hasta que vea un objetivo, que en ese caso debe huir a un punto del mapa.

4. Se les cronometra desde el momento en el que se les indique que pueden empezar hasta que consigan una ejecución que satisfaga a los objetivos propuestos.
5. Se les pide que realicen los mismos BTs con la herramienta.
6. Se les pide que rellenen un formulario sobre la usabilidad y calidad de la herramienta.

Para cada BT que debería ser creado se hicieron dos escenarios distintos, uno en el que se deba usar la herramienta y otro en la que el NPC ejecuta un BT creado a mano. Para el primer BT se ha hecho una copia del tercer escenario mencionado en la sección 3.4, con un objetivo y un punto de patrulla cerca de él en el mapa. El segundo escenario consta de un objetivo, dos flores rojas (una de ellas en frente el objetivo para que el NPC tenga que pasar por delante de él) y un punto de patrulla alejado del objetivo.

El formulario, que se puede encontrar en el apéndice D, mide la usabilidad y la calidad de la herramienta frente a BTs creados por un humano. Para la usabilidad se ha decidido evaluar mediante el System Usability Scale (SUS), introducido en Brooke (1996), que consiste en un cuestionario estandarizado de 10 items que siguen la escala de Likert de 5 puntos, que van desde “Totalmente en desacuerdo” a “Totalmente de acuerdo”. Este método de evaluación se ha decidido seguir por evidencias de su robustez en estudios como Bangor et al. (2008) o Peres et al. (2013).

Para la calidad de la herramienta se les han realizado preguntas sobre los resultados esperados de tiempos de ejecución, diferencias entre la calidad y similitud de sus BTs y los generados por la herramienta, y su funcionalidad como punto de partida. Finalmente se ha habilitado un campo de texto no obligatorio de respuestas libres donde los usuarios podrían expresar su opinión sobre los BTs generados y la herramienta.

Debido al perfil específico que se necesitaban para las pruebas solo se han podido realizar pruebas con 3 usuarios, por lo que las conclusiones sirven como una aproximación pero no se deben tomar como concluyentes.

En cuanto a la usabilidad podemos ver los resultados individuales en la tabla 5.1 y en la figura 5.1 que se ha obtenido una media de 90.83 sobre 100 con una desviación estándar de 15.88, lo cual supera con creces la media de 68 establecida por el artículos como Hyzy et al. (2022), por lo que dadas estas pruebas se puede decir que la herramienta cumple con el objetivo de accesibilidad, haciéndola así fácil de utilizar y confirmando con los datos dados H4.

Tabla 5.1: Resultados de la encuesta SUS

Usuario	Puntuación
U1	72.5
U2	100
U3	100




Figura 5.1: Resultados de la encuesta SUS de los usuarios sobre la usabilidad de la herramienta.

La comparativa de los tiempos podemos verla en la tabla 5.2 y en la figura 5.2, en donde a excepción del primer BT que ha tardado más en generarlo la herramienta que el segundo usuario, hay una diferencia significativa en cuanto a la tardanza, beneficiando a los generados por la herramienta. Además, como podemos ver en la figura 5.3, los usuarios tienen una opinión favorable sobre los tiempos de ejecución de la herramienta con una media del 86.6 %, afirmando así la hipótesis inicial de generar de forma más rápida los BTs con unos tiempos de generación adecuados (H1).

Tabla 5.2: Tiempo (en segundos) de generación de cada BT por cada usuario

Usuario	BT 1 manual	BT 1 herramienta	BT 2 manual	BT 2 herramienta
U1	578	238	332	142
U2	315	486	159	35
U3	271	35	174	37




Figura 5.2: Comparación de cuánto han tardado en crear los usuarios los BTs junto a cuánto ha tardado la herramienta.




Figura 5.3: Opinión de los usuarios sobre los tiempos de ejecución de la herramienta del 1 al 5, siendo 1 una opinión desfavorable y 5 la más favorable.

Siguiendo con la calidad de los BTs podemos observar en las figuras 5.4 y 5.5 que la calidad de los BTs es inferior a los generados por un humano (con una media en las respuestas del 80 %), pero que cumplen con la ejecución esperada (con una media de las respuestas del 80 % también). Esto se puede explicar gracias a las respuestas de las preguntas sobre si los BTs generados tenían más nodos de los necesarios y si eran distintos a los generados por los humanos, en los que todos los usuarios respondieron que la herramienta añadía algunos nodos extra (tanto compuestos como tareas innecesarias) y que esto hacía que los BTs generados fuesen distintos a los creados manualmente, dando una calidad inferior pero con una ejecución similar, confirmando así la hipótesis H2.




Figura 5.4: Respuestas de los usuarios sobre la calidad de los BTs generados por la herramienta, donde 1 es que no están de acuerdo con la afirmación de que la calidad de los BTs generados por la herramienta son inferiores y 5 es que están completamente de acuerdo.




Figura 5.5: Respuestas de los usuarios sobre la ejecución esperada de los BTs, donde 1 es que consideran una mala ejecución y 5 significa una ejecución correcta.

Finalmente y junto a los resultados del apartado de calidad, la comprobación de

H3 se puede apoyar en los resultados de las figuras 5.6, 5.7 y 5.8, donde podemos ver que los usuarios han tenido una buena opinión sobre la idea de la usabilidad de la herramienta como apoyo para los diseñadores, respondiendo con un 93.4 % a la opinión de que sirve como buen punto de partida y que, gracias a la facilidad de modificación de los JSONs generados (con una media de respuestas del 86.6 %), la herramienta puede servir para disminuir la carga de trabajo de los diseñadores (con una opinión del de media 93.4 %).




Figura 5.6: Respuestas de los usuarios donde indican si los BTs generados sirven como punto de partida (5) o no (1)




Figura 5.7: Respuestas de los usuarios sobre la facilidad para modificar los BTs generados, donde 1 es significa que es difícil y 5 significa que es fácil.




Figura 5.8: Respuestas de los usuarios sobre su opinión de si la herramienta puede disminuir (5) o no (1) la carga de trabajo de los diseñadores.

Capítulo 6

Resultados

Este trabajo ha consistido en la creación de una herramienta para la generación automática de Behavior Trees (BTs) para personajes no jugador (NPCs) en videojuegos con el fin de disminuir la carga de trabajo de los diseñadores de videojuegos. Para ello se escogió el motor de videojuegos Unreal Engine 5.7 como base donde poder implementar nodos necesarios para la generación de comportamientos (tanto como tareas como condicionales) y donde desarrollar una serie de escenarios para probar los BTs generados. Una vez se tenía todo lo necesario para poder crear y ejecutar BTs se ha procedido con el diseño de la herramienta que los genera. Esta herramienta consta de dos LLMs: el primero, de un tamaño elevado (Mistral Large 3, con 675B de parámetros), traduce la petición en lenguaje natural a pseudocódigo, mientras que un segundo LLM de menor tamaño (ollama3:8B, con 8B de parámetros) se encarga de asignar las variables de la Blackboard a los nodos necesarios. Para evaluar los BTs se han diseñado dos sistemas de validación: un validador de dependencias entre nodos mediante un autómata finito no determinista y un validador de objetivos cumplidos. Finalmente se han realizado pruebas de usuario para verificar si se cumplen los objetivos planteados.

Los resultados obtenidos de las implementaciones de cada parte del trabajo se detallan a continuación.

6.1. Resultados de los escenarios

Las acciones y condicionales implementados en Unreal Engine 5, así como los diferentes escenarios, han conseguido cumplir su función como marco en el que ejecutar los BTs generados, consiguiendo el objetivo de cumplir con una opacidad del modelo frente a los usuarios.

6.2. Resultados de la herramienta generadora de árboles de comportamiento

Con el modelo LLM usado para la generación de pseudocódigo se ha conseguido una generación de BTs generalmente correcta en cuanto a calidad de ejecución, tiempo de generación y el formato resultante, consiguiendo una baja latencia debido al uso de un modelo en la nube. Al ser un modelo que se accede mediante API, se ha tenido que recurrir debido a sus limitaciones de acceso al uso de un modelo más pequeño para la asignación de variables de la Blackboard. Esto ha resultado en algunos fallos a la hora de fijar las variables, siendo un motivo por el que los usuarios tuviesen que revisar y cambiar los JSONs resultantes, aunque estos fallos no han sido habituales durante el transcurso de todo este trabajo.

Para el sistema RAG montado se han buscado datasets de BTs con el fin de usarlos como ejemplos de generaciones. Al no encontrar específicamente de videojuegos se ha optado por el uso de un dataset de robótica¹. Aunque sea un dataset de un campo distinto ha cumplido la función de reducir las alucinaciones, generando de esta forma BTs son un menor número de nodos adicionales o una selección de tipo de nodo de composición más certera. Un aspecto negativo de este sistema es el aumento del tiempo de ejecución de la herramienta en las ocasiones en las que el almacén vectorial no estaba guardado en memoria, retrasando de este modo el tiempo de generación unos cuantos segundos.

También para disminuir las alucinaciones se ha hecho uso de varias técnicas de *prompt engineering* tales como “Few-shot prompting” o “Chain-of-Thought” con lo que se ha conseguido unos BTs capaces de lograr los comportamientos pedidos. Una técnica fundamental ha sido “Self-Critique Prompting”, ya que ha conseguido corregir algunos errores alucinaciones de invención de nombres de tareas, decoradores o fallos en la sintaxis del pseudocódigo.

Todos estos aspectos han conseguido lograr unos BTs que, aún no ser completamente perfectos, sirven como una buena base para generar comportamientos sobre los que el diseñador pueda trabajar de manera sencilla, reduciendo así su carga de trabajo.

6.3. Resultados del sistema de validación automática

La validación automática ha servido para comprobar dos aspectos: el cumplimiento de las dependencias entre tareas y del objetivo de cada comportamiento. Esos métodos de verificación han resultado cumplir su función de forma adecuada, consiguiendo en los casos en los que los BTs resultaban fallidos, la herramienta fuese capaz de comprender mejor la acción buscada y reestructurar el BT para conseguir uno más adecuado. Esto se ha podido comprobar en tres escenarios que se han desarrollado y en los que se han conseguido generaciones completamente válidas.

¹Acceso al dataset LLM-BRAIn (Lykov y Tsetserukou (2023): https://huggingface.co/datasets/ArtemLykov/LLM-BRAIn_dataset)

6.4. Resultados de las pruebas de usuarios

Como bien se ha comentado en la sección 5 se han realizado unas pruebas con un número de usuarios reducido ($N=3$), por lo que las conclusiones no se deben tomar como definitivas sino como una aproximación. Teniendo en cuenta esto se han conseguido los siguientes resultados:

- Según la observación experimental los usuarios tardaban más en realizar los BTs que en generarlos a mano.
- La herramienta generaba BTs que conseguían una generación similar a los realizados a mano.
- Los BTs generados colocaban nodos extra o no lograban asignar correctamente todas las variables de la Blackboard a las tareas, haciendo que los BTs generados fuesen de una calidad inferior a los humanos, aunque formando una base para que la intervención de los diseñadores fuese mínima.
- La encuesta SUS realizada para medir la usabilidad dio un resultado de media de 90.83 y desviación típica de 15.88, superando el umbral de lo aceptable establecido por la literatura de 68.

Conclusiones y Trabajo Futuro

El objetivo de este estudio consistía en la creación de una herramienta que, dadas unas tareas y unos condicionales, fuese capaz de generar árboles de comportamiento para personajes no jugador que sirviesen como base para rebajar la carga de trabajo de los diseñadores de videojuegos.

Dados los resultados anteriormente mencionados se han llegado a las siguientes conclusiones y limitaciones.

7.1. Conclusiones

Aunque de forma preliminar debido a la escasez de usuarios encontrados para las pruebas de usuario, se ha llegado a la conclusión de que este modelo es capaz de generar árboles de comportamiento funcionales en un tiempo inferior al de un humano, consiguiendo así el objetivo general planteado.

7.2. Limitaciones

Este trabajo ha sufrido una serie de limitaciones en cuanto a limitaciones técnicas y a la escasez de usuarios disponibles para las pruebas.

Las limitaciones técnicas se han podido comprobar a la hora de la selección de modelos para generar los BTs. Como bien se ha mencionado anteriormente de los dos modelos, a pesar de cumplir de forma correcta su objetivo, presentan una serie de limitaciones debido a las capacidades computacionales disponibles. El modelo generador de pseudocódigo es un LLM en la nube, teniendo que depender de una API de terceros, lo que no permite un control total del modelo. Adicionalmente, el modelo que asigna las variables de la Blackboard es uno bastante pequeño que puede cometer errores. Además, el sistema RAG se ha construido con BTs de robótica y no de videojuegos y que puede tardar varios segundos en construirse. Otra limitación es la falta de automatización en ciertos aspectos, como en la suscripción de las tareas a la Abstract Factory así como la asignación de su descripción. Aunque los usuarios encuestados encontrasen sencilla la modificación de los BTs generados, es posible que en el futuro busquen cambios adicionales en el comportamiento o necesiten

reestructurarlo de forma sencilla, lo cual en el estado actual supondría pedirle otra generación distinta a la herramienta en vez de partir con el BT ya existente.

Finalmente la limitación más grande ha sido la falta de usuarios para poder realizar las pruebas de usuarios, haciendo imposible concluir de forma definitiva las hipótesis planteadas siguiendo los objetivos.

Todas estas limitaciones han llevado al siguiente plan de trabajo a futuro.

7.3. Trabajo Futuro

El trabajo a futuro de este estudio se puede centrar en varios esfuerzos:

- Con capacidades computacionales mayores estudiar el uso de modelos locales de mayor tamaño para los modelos usados, así como el uso de técnicas de Fine-tuning para comprobar si su uso alcanzaría o mejoraría los resultados actuales con el fin de no depender de APIs de terceros.
- Mejorar el sistema RAG con BTs de videojuegos y, adicionalmente, que se guarden en disco el almacén vectorial y se puedan buscar por metadatos gracias al uso de Qdrant, suponiendo así una posible mejora en el contexto dado a los modelos y reduciendo la latencia.
- Implementar un agente LLM con una interfaz visual para cambiar los BTs generados de forma más sencilla y que se le pueda dar feedback al generador mediante uso de lenguaje natural.
- Implementar un agente LLM que pueda leer las acciones y descripciones de los proyectos para automatizar su suscripción a la Abstract Factory y su descripción para el paso a la herramienta.
- Recopilar más usuarios para las pruebas con el fin de conseguir un número estadísticamente significativo para concluir definitivamente las hipótesis propuestas.

Introduction

In recent years, the advancement of immersive technologies such as [VR](#) has brought about a significant change in how users interact in digital environments. Major companies like Meta and Apple have invested in the development of hardware for these technologies, launching devices like the Meta Quest 3 and Apple Vision Pro, and creating social interaction platforms in the [metaverse](#) with the development of Meta Horizon Worlds. This technology has opened new opportunities to explore more natural modes of communication in virtual spaces through non-verbal communication.

Non-verbal communication refers to the transmission of messages without the use of words, relying instead on images and gestures. In our daily lives, it plays a crucial role in human interactions, yet its representation in virtual environments is often limited and dependent on predefined actions such as animations or "emotes" already integrated into the game. Therefore, the development of tools that can capture and interpret these gestures in real-time represents a significant step towards creating more expressive and realistic virtual environments.

7.4. Motivation

As mentioned in the introduction, the use of non-verbal communication in virtual environments is limited and predefined by their design, restricting a fundamental part of everyday human expression. Due to this, and as seen in articles like [? or ?](#), gesture detection is a field of study currently being explored to address this issue. For these reasons, it is interesting to investigate ways to expand this representation of non-verbal communication so that interaction between users and [NPCs](#) becomes more natural.

This work is therefore part of the research line focused on developing tools that can recognize gestures performed by a user using a motion capture suit, with the aim of creating more immersive and natural virtual environments for users. On the other hand, a large amount of data is required to create [AI](#) models that enable the development of the mentioned tools. In the case of this project, the necessary data consists of a sequence of 3D coordinates representing the positions and rotations of the skeleton's bones throughout the animations, resulting in relatively large data sizes. This necessitates the creation of complex models capable of processing a

significant amount of input data. However, as we will discuss throughout the work, it has not been possible to find datasets containing this type of data. As a result, a significant contribution of this work to the field has been the creation of a dataset through the extraction of animations from a specialized bank and the motion capture of users.

Given these reasons, it can be concluded that the lack of natural methods to leverage non-verbal communication in virtual environments and the scarcity of animation datasets have motivated the objectives mentioned, which we will expand upon below.

7.5. Objectives

The general objective of this project is to implement an [AI](#) model that, with low latency, allows real-time identification of gestures performed with a motion capture suit, aiming to enhance non-verbal communication in virtual environments. To achieve this objective, the following goals have been proposed during the development of the work:

1. Search for animation datasets that are considered relevant for communicating with an [NPC](#) in a video game. These animations include dancing, greeting, pointing, sitting, fighting, and running.
2. Automatic extraction of the aforementioned animations from animation banks and subsequent processing.
3. Extraction of animations through motion capture from a heterogeneous group of users.
4. Implementation, training, and comparison of different [AI](#) models, including neural networks (LSTM, CNN, and RNN) as well as classical classification models (Random Forest).
5. Development of a final application as a demonstration to showcase the results in [VR](#) to enhance immersion.

As a significant secondary objective, due to the lack of animation datasets, it has been proposed to publish the resulting datasets, both from artificial animations and user captures.

7.6. Work Plan

The work plan consists of several steps:

1. Search for a dataset: generate a sufficiently large dataset with multiple examples of gestures to adequately train different models. This dataset should primarily consist of data from real users to identify the most natural gestures possible.

- 2. Implementation of AI models: implement various AI models to compare them and determine which one is most suitable based on prediction speed and accuracy. The implementation of these models should include: training, a way to extract final model statistics, hyperparameter search, confusion matrix generator, and compatibility with a common user interface for all trainings.
- 3. Development of a user interface for training and monitoring different models: develop a web interface so that users with less programming and AI experience can train models capable of predicting the gestures they need without modifying the code or needing to understand the internal workings of the codebase.
- 4. Development of a final application: create an application for Oculus Quest as a demo that connects to the chosen model and allows real-time usage demonstration.

The development of tasks and their planning can be seen in Figure 7.1.




Figure 7.1: Gantt chart of the project

Conclusions and Future Work

7.7. Conclusions

The objective of this study was to create an [AI](#) model capable of detecting a series of gestures from users wearing a motion capture suit. To achieve this, datasets of gestures that matched the study's constraints were sought. Since no easily adaptable datasets with the required gestures were found, an animation dataset was created, consisting of both computer-generated data and data collected from real users. The computer-generated animations were converted to [CSV](#) format using a tool created by the authors of the study, while the animations collected from real users were processed with another tool developed by the same authors. After training various [AI](#) models, it was concluded that the [Random Forest](#) model is the best choice for several reasons. Following this, a demonstration application was created to showcase the final results.

The conclusions of each part of the work are presented in the following sections in more detail.

7.7.1. Dataset Search Conclusions

After the search for animation datasets, it was concluded that there are not enough public datasets available for the objective of this study.

These conclusions led us to the need to create our own dataset by collecting animations from animation banks and through user trials.

7.7.2. Conclusions of the Animation Extraction Tool

The gesture conversion tool fully meets its objective, as it only requires specifying the name of the folder containing the downloaded gestures. It automatically processes the gestures in Unity and uploads them to Kaggle. Additionally, the tool is independent of the number of gestures to be converted and the number of animations available for those gestures, achieving great scalability. This allows for the introduction of new gestures without requiring any changes to the tool.

7.7.3. Conclusions of the User Data Collection

As can be seen in the figures in Appendix ??, the participant group—except for the non-binary gender category—is heterogeneous in terms of gender, with only a small percentage difference between men and women. The most notable difference can be seen in users' dominant hand, with left-handed individuals making up only 6.15% of the group's total population.

Thanks to the test, a total of 975 animations were obtained (195 animations each for waving, pointing, sitting, fighting, and running).

7.7.4. Conclusions of the IA Models Comparison

In terms of the AI models, it has been observed that neural network models did not achieve the expected results, likely due to a combination of insufficient data and simplification of the neural networks to ensure shorter training times and faster inference computations.

However, the Random Forest model has yielded the best results, being the fastest model (both in inference and training), the lightest model, and the most adaptable. This model can be used in systems with limited resources, such as standalone VR glasses like Meta Quest or more powerful computers, and even in AI ecosystems due to its possible translation to TensorFlow already implemented.

In the analysis of the Random Forest results, it has been observed that the model places significant importance on the y-coordinate of the left leg and the y-coordinate of the left foot in the second time interval. This may indicate that gestures heavily depend on leg positions to distinguish between running, dancing, waving, or pointing.

Also, there is a slight confusion between the gestures of fighting and waving. This may be due to the rapid hand movements in both types of gestures, which, due to the lack of fingers in the suit, can lead to confusion between a punch and a wave.

7.7.5. Final Application Conclusions

The final application is a demo that connects to a server to display the results.

The negative aspect of this application is the way it connects to the server where the model is hosted, as it makes direct web requests to the Tensor Serving server, making it dependent on that server.

Finally, the final application fulfills its purpose of showing the user the predicted animation with minimal latency.

7.7.6. Limitations

This study has faced a series of limitations, including the scarcity of public datasets, imbalance in types of animations, lack of more data from real users, training issues with neural network models, and data shortages for those same models.

The limitation of dataset scarcity is not only due to the lack of datasets in number but also to the lack of gestures related to non-verbal communication. Most

available datasets focus on sports or very specific themes, with few general-purpose datasets. Another limitation of these datasets has been the ease of adaptation or conversion to a format compatible with the motion capture suit used in the study.

Regarding the imbalance of animation types, the issue arises from the duration of Mixamo's dance animations. Following the standardization process, the various dance animations are multiplied by a significantly larger number than those of other types. This was not resolved with the data collected from real users, as even though a large number of new animations were obtained, after standardization, dance animations still predominated significantly. This can be seen in Figures ?? and ??.

The neural network models did not yield the expected results, which may be due to the lack of data. Although there appears to be a sufficient number of samples at first glance, it is not enough for training neural networks. Additionally, hardware limitations for training more complex models and the time constraints of this study did not allow for longer training sessions or more extensive hyperparameter searches.

All these limitations have led to the following future work plan.

7.8. Future Work

The future work of this study can focus on several efforts:

- Improve the dataset by including people with functional diversity, increasing the number of samples per gesture, considering finger movements, and adding new categories. This could not only enhance the performance of neural network models but also provide greater differentiation for better generalization.
- Investigate other [AI](#) models that could improve classification accuracy and enable classification not only of gestures but also of emotions. This could help [NPCs](#) react more naturally to user gestures, making interactions more immersive.
- Standardize the server to be compatible with other [AI](#) technologies beyond TensorFlow. This would allow for the integration of emerging technologies into existing applications.
- Implement another model that considers not only the current predicted gesture but also the entire context to advance the use of non-verbal communication with [NPCs](#).
- Evaluation of the final result with users.

Bibliografía

The sciences, each straining in its own direction, have hitherto harmed us little; but some day the piecing together of dissociated knowledge will open up such terrifying vistas of reality, and of our frightful position therein, that we shall either go mad from the revelation or flee from the deadly light into the peace and safety of a new dark age.

H.P. Lovecraft, *The Call of Cthulhu*

- AGIS, R. A., GOTTIFREDI, S. y GARCÍA, A. J. An event-driven behavior trees extension to facilitate non-player multi-agent coordination in video games. *Expert Systems with Applications*, vol. 155, página 113457, 2020. ISSN 0957-4174.
- AHN, M., BROHAN, A., BROWN, N., CHEBOTAR, Y., CORTES, O., DAVID, B., FINN, C., FU, C., GOPALAKRISHNAN, K., HAUSMAN, K., HERZOG, A., HO, D., HSU, J., IBARZ, J., ICHTER, B., IRPAN, A., JANG, E., RUANO, R. J., JEFFREY, K., JESMONTH, S., JOSHI, N. J., JULIAN, R., KALASHNIKOV, D., KUANG, Y., LEE, K.-H., LEVINE, S., LU, Y., LUU, L., PARADA, C., PASTOR, P., QUIAMBAO, J., RAO, K., RETTINGHOUSE, J., REYES, D., SERMANET, P., SIEVERS, N., TAN, C., TOSHEV, A., VANHOUCKE, V., XIA, F., XIAO, T., XU, P., XU, S., YAN, M. y ZENG, A. Do as i can, not as i say: Grounding language in robotic affordances. 2022.
- AO, J., WU, F., WU, Y., SWIKIR, A. y HADDADIN, S. Llm-as-bt-planner: Leveraging llms for behavior tree generation in robot task planning. 2025.
- BANGOR, A., KORTUM, P. T. y MILLER, J. T. An empirical evaluation of the system usability scale. *International Journal of Human-Computer Interaction*, vol. 24(6), páginas 574–594, 2008.
- BECROFT, D., BASSETT, J., MEJIA, A., RICH, C. y SIDNER, C. AIPaint: A sketch-based behavior tree authoring tool. *Proc. AAAI Artif. Intell. Interact. Digit. Enterain. Conf.*, vol. 7(1), páginas 2–7, 2011.

- BEN-ARI, M. y MONDADA, F. *Finite State Machines*, páginas 55–61. Springer International Publishing, Cham, 2018. ISBN 978-3-319-62533-1.
- BENGIO, Y., DUCHARME, R., VINCENT, P. y JANVIN, C. A neural probabilistic language model. *J. Mach. Learn. Res.*, vol. 3(null), página 1137–1155, 2003. ISSN 1532-4435.
- BERGER, A. L., DELLA PIETRA, S. A. y DELLA PIETRA, V. J. A maximum entropy approach to natural language processing. *Computational Linguistics*, vol. 22(1), páginas 39–71, 1996.
- BROOKE, J. SUS-A quick and dirty usability scale. *Usability evaluation in industry*, vol. 189(194), 1996.
- BROWN, T. B., MANN, B., RYDER, N., SUBBIAH, M., KAPLAN, J., DHARIWAL, P., NEELAKANTAN, A., SHYAM, P., SASTRY, G., ASKELL, A., AGARWAL, S., HERBERT-VOSS, A., KRUEGER, G., HENIGHAN, T., CHILD, R., RAMESH, A., ZIEGLER, D. M., WU, J., WINTER, C., HESSE, C., CHEN, M., SIGLER, E., LITWIN, M., GRAY, S., CHESSE, B., CLARK, J., BERNER, C., MCCANDLISH, S., RADFORD, A., SUTSKEVER, I. y AMODEI, D. Language models are few-shot learners. 2020.
- CAMACHO, A., TRIANTAFILLOU, E., MUISE, C., BAIER, J. y MCILRAITH, S. Non-deterministic planning with temporally extended goals: LTL over finite and infinite traces. *Proc. Conf. AAAI Artif. Intell.*, vol. 31(1), 2017.
- CHO, K., VAN MERRIËNBOER, B., GULCEHRE, C., BAHDANAU, D., BOUGARES, F., SCHWENK, H. y BENGIO, Y. Learning phrase representations using RNN encoder–decoder for statistical machine translation. En *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (editado por A. Moschitti, B. Pang y W. Daelemans), páginas 1724–1734. Association for Computational Linguistics, Doha, Qatar, 2014.
- CHOI, J.-W., KIM, H., ONG, H., YOON, Y., JANG, M., KIM, D. y KIM, J. Reac-tree: Hierarchical llm agent trees with control flow for long-horizon task planning. 2026.
- COLLEDANCHISE, M., ALMEIDA, D. y OGREN, P. Towards blended reactive planning and acting using behavior trees. En *2019 International Conference on Robotics and Automation (ICRA)*, página 8839–8845. IEEE, 2019.
- COLLEDANCHISE, M. y OGREN, P. How behavior trees modularize hybrid control systems and generalize sequential behavior compositions, the subsumption architecture, and decision trees. *IEEE Transactions on Robotics*, vol. 33, páginas 372–389, 2016.
- DEVLIN, J., CHANG, M.-W., LEE, K. y TOUTANOVA, K. Bert: Pre-training of deep bidirectional transformers for language understanding. 2019.

- ELMAN, J. L. Finding structure in time. *Cognitive Science*, vol. 14(2), páginas 179–211, 1990. ISSN 0364-0213.
- FATHONI, K., HAKKUN, R. Y. y NURHADI, H. A. T. Finite state machines for building believable non-playable character in the game of khalid ibn al-walid. *Journal of Physics: Conference Series*, vol. 1577(1), página 012018, 2020.
- FAUZI, R., HARIADI, M., NUGROHO, S. y LUBIS, M. Defense behavior of real time strategy games: Comparison between hfsm and fsm. *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 13(2), páginas 634–642, 2019. ISSN 2502-4752. Publisher Copyright: © 2019 Institute of Advanced Engineering and Science. All rights reserved.
- FLOREZ-PUGA, G., GÓMEZ-MARTÍN, M. y DÍAZ AGUDO, B. Dynamic expansion of behaviour trees. *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 4, páginas 36–41, 2008.
- GAJARDO, I., BESOAIN, F. y BARRIGA, N. A. Introduction to behavior algorithms for fighting games. En *2019 IEEE CHILEAN Conference on Electrical, Electronics Engineering, Information and Communication Technologies (CHILECON)*, página 1–6. IEEE, 2019.
- GANAPATHI, A., SIVAKUMAR, P., ELANGO, A., GUPTA, H. y PANDA, N. Exploring npc behaviors in games through finite automata. En *2024 5th IEEE Global Conference for Advancement in Technology (GCAT)*, páginas 1–8. 2024.
- GUGLIERMO, S., CÁCERES DOMÍNGUEZ, D., IANNOTTA, M., STOYANOV, T. y SCHAFFERNICHT, E. Evaluating behavior trees. *Robotics and Autonomous Systems*, vol. 178, página 104714, 2024. ISSN 0921-8890.
- GUO, S. y HOU, S. Analyzing Approaches to Extending and Implementing Behavior Trees in Computer Games. *Applied and Computational Engineering*, vol. 199(1), páginas 139–153, 2025.
- HOCHREITER, S. y SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, vol. 9(8), páginas 1735–1780, 1997. ISSN 0899-7667.
- HOFFMEISTER, L. M., SCASSELLATI, B. y RAKITA, D. Towards zero-knowledge task planning via a language-based approach. 2026.
- HOU, X., ZHAO, Y., WANG, S. y WANG, H. Model context protocol (mcp): Landscape, security threats, and future research directions. *ACM Trans. Softw. Eng. Methodol.*, 2026. ISSN 1049-331X. Just Accepted.
- HU, W., ZHANG, Q. y MAO, Y. Component-based hierarchical state machine — a reusable and flexible game ai technology. 2011.
- HUANG, W., XIA, F., XIAO, T., CHAN, H., LIANG, J., FLORENCE, P., ZENG, A., TOMPSON, J., MORDATCH, I., CHEBOTAR, Y., SERMANET, P., BROWN, N., JACKSON, T., LUU, L., LEVINE, S., HAUSMAN, K. y ICHTER, B. Inner monologue: Embodied reasoning through planning with language models. 2022.

- HYZY, M., BOND, R., MULVENNA, M., BAI, L., DIX, A., LEIGH, S. y HUNT, S. System Usability Scale Benchmarking for Digital Health Apps: Meta-analysis. *JMIR mHealth and uHealth*, vol. 10(8), página e37290, 2022.
- IOVINO, M., FÖRSTER, J., FALCO, P., CHUNG, J. J., SIEGWART, R. y SMITH, C. Comparison between behavior trees and finite state machines. *IEEE Transactions on Automation Science and Engineering*, vol. 22, páginas 21098–21117, 2025.
- IOVINO, M., SCUKINS, E., STYRUD, J., ÖGREN, P. y SMITH, C. A survey of behavior trees in robotics and ai. 2020a.
- IOVINO, M., SCUKINS, E., STYRUD, J., ÖGREN, P. y SMITH, C. A survey of behavior trees in robotics and ai. *Robotics and Autonomous Systems*, vol. 154, página 104096, 2022. ISSN 0921-8890.
- IOVINO, M., STYRUD, J., FALCO, P. y SMITH, C. Learning behavior trees with genetic programming in unpredictable environments. 2020b.
- IOVINO, M., STYRUD, J., FALCO, P. y SMITH, C. A framework for learning behavior trees in collaborative robotic applications. 2023.
- ITO, R., JIMBO, N. y IHARA, K. Pilot study on llm-based behavior tree generation. *Proceedings of the Annual Conference of JSAI*, vol. JSAI2026, páginas 2G1OS2103–2G1OS2103, 2026.
- IZZO, R. A., BARDARO, G. y MATTEUCCI, M. Btgenbot: Behavior tree generation for robotic tasks with lightweight llms. En *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, página 9684–9690. IEEE, 2024.
- JELINEK, F. y MERCER, R. L. Interpolated estimation of Markov source parameters from sparse data. En *Proc. Workshop on Pattern Recognition in Practice*. 1980.
- KIMDONGJU y KOHSEOK-JOO. Intelligent npc ai based on fsm and reinforcement learning: Implementation study of a 2d mobile idle rpg game. *The Transactions of the Korea Information Processing Society*, vol. 14(6), páginas 480–488, 2025.
- LEE, M. An artificial intelligence evaluation on fsm-based game npc. *Journal of Korea Game Society*, vol. 14, páginas 127–135, 2014.
- LI, F., WANG, X., LI, B., WU, Y., WANG, Y. y YI, X. A study on training and developing large language models for behavior tree generation. 2024.
- LIM, C., BAUMGARTEN, R. y COLTON, S. Evolving behaviour trees for the commercial game defcon. En *Applications of Evolutionary Computation - EvoApplications 2010*, número PART 1 en Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), páginas 100–110. 2010. ISBN 3642122388. European Workshop on Bio-inspired Algorithms in Games 2010, EvoGAMES 2010 ; Conference date: 07-04-2010 Througth 09-04-2010.

- LIU, B., JIANG, Y., ZHANG, X., LIU, Q., ZHANG, S., BISWAS, J. y STONE, P. Llm+p: Empowering large language models with optimal planning proficiency. 2023.
- LLANSÓ, D., GÓMEZ-MARTÍN, M. y GONZÁLEZ-CALERO, P. Self-validated behaviour trees through reflective components. *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 5, páginas 70–75, 2009.
- LYKOV, A. y TSETSERUKOU, D. Llm-brain: Ai-driven fast generation of robot behaviour tree based on large language model. 2023.
- MERINO-FIDALGO, S., SÁNCHEZ-GIRÓN, C., ZALAMA, E., GÓMEZ-GARCÍA-BERMEJO, J. y DUQUE-DOMINGO, J. Behavior tree generation and adaptation for a social robot control with llms. *Robotics and Autonomous Systems*, vol. 194, página 105165, 2025. ISSN 0921-8890.
- MIKOLOV, T., CHEN, K., CORRADO, G. y DEAN, J. Efficient estimation of word representations in vector space. 2013.
- NUR FITRIANI DEWI, E., RACHMAN, A. y ZAHIR, H. Implementation of hierarchical finite state machine for controlling 2d character animation in action video game. páginas 1–6. 2023.
- PADURARU, C., STEFANESCU, A. y PADURARU, M. Enhancing game ai behaviors with large language models and agentic ai. 2025.
- PARK, J. S., O'BRIEN, J. C., CAI, C. J., MORRIS, M. R., LIANG, P. y BERNSTEIN, M. S. Generative agents: Interactive simulacra of human behavior. 2023.
- PARK, S., DURFEE, E. H. y BIRMINGHAM, W. P. Use of markov chains to design an agent bidding strategy for continuous double auctions. *J. Artif. Intell. Res.*, vol. 22, páginas 175–214, 2004.
- PARTLAN, N., SOTO, L., HOWE, J., SHRIVASTAVA, S., EL-NASR, M. S. y MARSELLA, S. Evolvingbehavior: Towards co-creative evolution of behavior trees for game npcs. 2022.
- PERES, S. C., PHAM, T. y PHILLIPS, R. Validation of the system usability scale (sus): Sus in the wild. *Proceedings of the Human Factors and Ergonomics Society Annual Meeting*, vol. 57(1), páginas 192–196, 2013.
- PETERS, M. E., NEUMANN, M., IYYER, M., GARDNER, M., CLARK, C., LEE, K. y ZETTLEMOYER, L. Deep contextualized word representations. En *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)* (editado por M. Walker, H. Ji y A. Stent), páginas 2227–2237. Association for Computational Linguistics, New Orleans, Louisiana, 2018.
- RADFORD, A. y NARASIMHAN, K. Improving language understanding by generative pre-training. 2018.

- SAGREDO-OLIVENZA, I., GÓMEZ-MARTÍN, P. y GÓMEZ-MARTÍN, M. Trained behavior trees: Programming by demonstration to support ai game designers. *IEEE Transactions on Games*, vol. 11, páginas 5–14, 2017.
- SCHICK, T., DWIVEDI-YU, J., DESSÌ, R., RAILEANU, R., LOMELI, M., ZETTMAYER, L., CANCEDDA, N. y SCIALOM, T. Toolformer: Language models can teach themselves to use tools. 2023.
- SCHULHOFF, S., ILIE, M., BALEPUR, N., KAHADZE, K., LIU, A., SI, C., LI, Y., GUPTA, A., HAN, H., SCHULHOFF, S., DULEPET, P. S., VIDYADHARA, S., KI, D., AGRAWAL, S., PHAM, C., KROIZ, G., LI, F., TAO, H., SRIVASTAVA, A., COSTA, H. D., GUPTA, S., ROGERS, M. L., GONCEARENCO, I., SARLI, G., GALYNKER, I., PESKOFF, D., CARPUAT, M., WHITE, J., ANADKAT, S., HOYLE, A. y RESNIK, P. The prompt report: A systematic survey of prompt engineering techniques. 2025.
- SEKHAVAT, Y. Behavior trees for computer games. *International Journal on Artificial Intelligence Tools*, vol. 26, página 1730001, 2017.
- SONG, C. H., WU, J., WASHINGTON, C., SADLER, B. M., CHAO, W.-L. y SU, Y. Llm-planner: Few-shot grounded planning for embodied agents with large language models. 2023.
- THOMPSON, T. Cyber demons. <https://www.gamedeveloper.com/design/cyber-demons-the-ai-of-doom-2016->, 2018. Accessed: 2026-8-27.
- TREMBLAY, H., PONTON, D., GONZALEZ, L., FRANCILLETTE, Y. y BOUCHARD, B. Breaking down the challenge: A comprehensive framework for evaluating enemy difficulty with automated behavior tree analytics. *Entertainment Computing*, vol. 57, página 101096, 2026. ISSN 1875-9521.
- VALMEEKAM, K., MARQUEZ, M., OLMO, A., SREEDHARAN, S. y KAMBHAMPATI, S. Planbench: An extensible benchmark for evaluating large language models on planning and reasoning about change. 2023.
- VASWANI, A., SHAZEER, N., PARMAR, N., USZKOREIT, J., JONES, L., GOMEZ, A. N., KAISER, L. y POLOSUKHIN, I. Attention is all you need. 2023.
- WANG, L., MA, C., FENG, X., ZHANG, Z., YANG, H., ZHANG, J., CHEN, Z., TANG, J., CHEN, X., LIN, Y., ZHAO, W. X., WEI, Z. y WEN, J. A survey on large language model based autonomous agents. *Frontiers of Computer Science*, vol. 18(6), 2024. ISSN 2095-2236.
- WEI, J., BOSMA, M., ZHAO, V. Y., GUU, K., YU, A. W., LESTER, B., DU, N., DAI, A. M. y LE, Q. V. Finetuned language models are zero-shot learners. 2022.
- WEI, J., WANG, X., SCHUURMANS, D., BOSMA, M., ICHTER, B., XIA, F., CHI, E., LE, Q. y ZHOU, D. Chain-of-thought prompting elicits reasoning in large language models. 2023.

- RONG WEN, C. Q. S. D. X. W. H. C. S. W. D. Y. J. X. J. Tool learning with large language models: a survey. *Frontiers of Computer Science*, vol. 19, páginas 198343–, 2025. ISSN 2095-2228.
- YANNAKAKIS, M. *Hierarchical State Machines*, vol. 1872, páginas 315–330. 2001. ISBN 978-3-540-67823-6.
- YAO, S., ZHAO, J., YU, D., DU, N., SHAFRAN, I., NARASIMHAN, K. y CAO, Y. React: Synergizing reasoning and acting in language models. 2023.
- ZHOU, D., SCHÄRLI, N., HOU, L., WEI, J., SCALES, N., WANG, X., SCHUURMANS, D., CUI, C., BOUSQUET, O., LE, Q. y CHI, E. Least-to-most prompting enables complex reasoning in large language models. 2023.
- ÖGREN, P. y SPRAGUE, C. I. Behavior trees in robot control systems. *Annual Review of Control, Robotics, and Autonomous Systems*, vol. 5(1), página 81–107, 2022. ISSN 2573-5144.

JSON Schema para los Behavior Trees generados

Listing A.1: JSON Schema (Draft 2020-12) de los Behavior Trees generados

```

1  {
2    "$schema": "https://json-schema.org/draft/2020-12/schema",
3    "$id": "https://example.com/behaviour-tree.schema.json",
4    "title": "Behaviour Tree",
5    "type": "object",
6    "required": ["Blackboard", "Node"],
7    "additionalProperties": false,
8
9    "properties": {
10     "Blackboard": {
11       "type": "array",
12       "description": "Blackboard",
13       "items": {
14         "type": "object",
15         "additionalProperties": {
16           "type": "string",
17           "enum": ["Bool", "Int", "Float", "Vector",
18                  ↪ "Object", "String"]
19         }
20       }
21     },
22     "Node": {
23       "$ref": "#/$defs/TreeNodeWrapper"
24     }
25   },
26
27   "$defs": {
28     "TreeNodeWrapper": {
29       "type": "object",
30       "description": "Nodo del arbol",

```

```

31     "minProperties": 1,
32     "maxProperties": 1,
33     "additionalProperties": {
34         "$ref": "#/$defs/TreeNode"
35     }
36 },
37
38 "TreeNode": {
39     "type": "object",
40     "required": ["Type", "Decorators", "Nodes"],
41     "additionalProperties": false,
42
43     "properties": {
44         "Type": {
45             "type": "string",
46             "enum": ["Selector", "Sequence", "Task", "Parallel"]
47         },
48
49         "Name": {
50             "type": "string",
51             "description": "Nombre opcional del nodo"
52         },
53
54         "Decorators": {
55             "type": "array",
56             "items": {
57                 "type": "object",
58                 "additionalProperties": {
59                     "type": "string"
60                 }
61             }
62         },
63
64         "Task": {
65             "type": "string",
66             "description": "Nombre de la tarea"
67         },
68
69         "BlackboardEntries": {
70             "type": "array",
71             "description": "Entradas del Blackboard usadas por  

72                 ↪ el nodo",
73             "items": {
74                 "type": "string"
75             }
76         },
77
78         "Nodes": {
79             "type": "array",

```

```
79         "description": "Nodos hijos",
80         "items": {
81             "$ref": "#/$defs/TreeNodeWrapper"
82         }
83     }
84 }
85 ,
86 "Nodes": {
87     "type": "array",
88     "description": "Nodos hijos",
89     "minItems": 0,
90     "items": {
91         "type" : "object",
92         "required": ["Node"],
93         "additionalProperties" : false,
94         "properties": {
95             "Node": {
96                 "$ref": "#/$defs/TreeNode"
97             }
98         }
99     }
100 },
101
102 "allOf": [
103     {
104         "if": {
105             "properties": { "Type": { "const": "Task" } }
106         },
107         "then": {
108             "required": ["Task"]
109         }
110     }
111 ]
112 }
113 }
114 }
```


Apéndice **B**

Prompt del sistema para el [LLM](#)
generador del pseudocódigo

You are an expert in behavior trees and algorithm design.

Your task is to convert a high-level task description into a structured pseudocode

Input:

- * A task description

Requirements:

- * Use ONLY the provided actions and ONLY the provided conditions. Do NOT invent
- * Produce a deterministic and unambiguous pseudocode.
- * The structure must be easy to parse programmatically.
- * Explicitly represent:
 - Sequence (ordered execution)
 - Selector (fallback / OR logic / conditionals)
 - Conditions (checks)
 - Actions (leaf nodes)
- * Avoid natural language ambiguity. Use a strict format.

Pseudocode Format Rules:

- * Use uppercase keywords: SEQUENCE, SELECTOR, IF, THEN, ELSE, END
- * You don't have to use all the keywords, only use the necessary ones.
- * Indentation must reflect hierarchy
- * Each condition must be written as: IF condition_name. Use ONLY the names from
- * Each action must be written as: DO action_name. Use ONLY the names from the "
- * ONLY blocks of SEQUENCE and SELECTOR must always be explicitly closed with EN
- * No free text explanations, only pseudocode

Behavior Tree Mapping:

- * SEQUENCE: executes children in order until one fails. Perfect for when action
- * SELECTOR: executes children until one succeeds. Perfect for when you have to
- * IF condition THEN ... ELSE ... : conditional branching

Reasoning Procedure:

Before generating the pseudocode, internally perform the following reasoning.

Do NOT output these steps.

Phase 1

Understand the global objective.

Identify:

- * the final goal;
- * mandatory subtasks;
- * optional subtasks.

Phase 2

Analyse the available actions.

For every action determine internally:

- * what it achieves;
- * when it is useful;

JSON de dependencias de tareas en un Behavior Tree

Listing C.1: Ejemplo del formato que deben seguir los JSON con el orden de dependencias de tareas

```

1 {
2   {
3     "Tasks" : [
4       {
5         "Name" : "HasLineOfSight?",
6         "Childs" : [
7           {
8             "Name" : "ChasePlayer",
9             "Childs" : [
10              {
11                "Name" : "MoveTo",
12                "Childs" : [
13                  {
14                    "Name" : "IsItNear?",
15                    "Childs" : [
16                      {
17                        "Name" : "Attack",
18                        "Childs" : []
19                      }
20                    ]
21                  }
22                ]
23              }
24            ]
25          }
26        ]
27      },
28      {
29        "Name" : "SelectWaypoint",
30        "Childs" : [

```

```
31      {
32          "Name" : "MoveTo",
33          "Childs" : []
34      }
35  ]
36  }
37  ]
38  }
39  }
```

Apéndice	D
----------	----------

Formulario de opiniones de la herramienta

26/8/26, 16:52

Herramienta para la generación de Behavior Trees

Herramienta para la generación de Behavior Trees

* Indica que la pregunta es obligatoria

1. Usuario *

Usabilidad de la herramienta

En esta sección se le realizarán preguntas sobre la usabilidad de la herramienta.

2. Creo que me gustaría utilizar este sistema con frecuencia *

Marca solo un óvalo.

1 2 3 4 5
Totalmente de acuerdo

3. Encontré el sistema innecesariamente complejo *

Marca solo un óvalo.

1 2 3 4 5
Totalmente de acuerdo

4. Pensé que el sistema era fácil de usar *

Marca solo un óvalo.

1 2 3 4 5
Totalmente de acuerdo

5. Creo que necesitaría el apoyo de un técnico para poder utilizar este sistema *

Marca solo un óvalo.

1 2 3 4 5
Totalmente de acuerdo

6. Encontré que las funciones de este sistema estaban bien integradas *

Marca solo un óvalo.

1 2 3 4 5
Totalmente de acuerdo

Figura D.1: Formulario de recogida de datos demográficos (primera parte)

26/8/26, 16:52

Herramienta para la generación de Behavior Trees

7. Encontré que las funciones de este sistema estaban bien integradas *

Marca solo un óvalo.

	1	2	3	4	5	
Total	☐	☐	☐	☐	☐	Totalmente de acuerdo

8. Pensé que había demasiada inconsistencia en este sistema *

Marca solo un óvalo.

	1	2	3	4	5	
Total	☐	☐	☐	☐	☐	Totalmente de acuerdo

9. Me imagino que la mayoría de la gente aprendería a utilizar este sistema muy rápidamente *

Marca solo un óvalo.

	1	2	3	4	5	
Total	☐	☐	☐	☐	☐	Totalmente de acuerdo

10. Me imagino que la mayoría de la gente aprendería a utilizar este sistema muy rápidamente *

Marca solo un óvalo.

	1	2	3	4	5	
Total	☐	☐	☐	☐	☐	Totalmente de acuerdo

11. Encontré el sistema muy complicado de usar *

Marca solo un óvalo.

	1	2	3	4	5	
Total	☐	☐	☐	☐	☐	Totalmente de acuerdo

12. Me sentí muy seguro usando el sistema *

Marca solo un óvalo.

	1	2	3	4	5	
Total	☐	☐	☐	☐	☐	Totalmente de acuerdo

Figura D.2: Formulario de recogida de datos demográficos (segunda parte)

26/8/26, 16:52

Herramienta para la generación de Behavior Trees

13. Necesitaba aprender muchas cosas antes de empezar con este sistema *

Marca solo un óvalo.

	1	2	3	4	5
Totale	☐	☐	☐	☐	☐

Totalmente de acuerdo

Calidad de la herramienta

14. El tiempo de generación de BTs ha sido adecuado *

Marca solo un óvalo.

	1	2	3	4	5
Totale	☐	☐	☐	☐	☐

Totalmente de acuerdo

15. La ejecución de los BTs generados ha resultado ser la esperada *

Marca solo un óvalo.

	1	2	3	4	5
Totale	☐	☐	☐	☐	☐

Totalmente de acuerdo

16. La calidad de los BTs generados es inferior a los generados por un humano *

Marca solo un óvalo.

	1	2	3	4	5
Totale	☐	☐	☐	☐	☐

Totalmente de acuerdo

17. ¿Los BTs generados han introducido más nodos de los necesarios? Contando todos los BTs generados, ¿cuántos?

18. ¿Cómo de distintos son los BTs creados por ti con los BTs generados?

Figura D.3: Formulario de recogida de datos demográficos (tercera parte)

26/8/26, 16:52

Herramienta para la generación de Behavior Trees

19. Los BTs generados son un buen punto de partida a la hora de crear BTs *

Marca solo un óvalo.

	1	2	3	4	5	
Tota	☐	☐	☐	☐	☐	Totalmente de acuerdo

20. ¿Consideras necesaria la intervención humana en esta herramienta para poder refinar los resultados o los BTs generados han sido lo suficientemente buenos como para no tener que modificarlos?

21. Los BTs generados se pueden modificar fácilmente *

Marca solo un óvalo.

	1	2	3	4	5	
Tota	☐	☐	☐	☐	☐	Totalmente de acuerdo

22. Esta herramienta podría hacer que disminuya la carga de trabajo de un diseñador *

Marca solo un óvalo.

	1	2	3	4	5	
Tota	☐	☐	☐	☐	☐	Totalmente de acuerdo

Opiniones

En esta sección es libre de expresar cualquier opinión respecto a los BTs generados o la herramienta.

23. Respuesta libre

Este contenido no ha sido creado ni aprobado por Google.

Google Formularios

Figura D.4: Formulario de recogida de datos demográficos (cuarta parte)

Glosario

Abstract Factory	El patrón Abstract Factory es un patrón de programación que consiste en mantener una clase que permita crear instancias de objetos relacionados gracias al polimorfismo.
AI	Artificial Intelligence
Almacén vectorial	Un almacén vectorial (o vector store) es una base de datos especializada en el almacenaje de la información en forma de vectores (o embeddings), la cual permite recuperar los datos por similitud matemática a otros vectores.
API	Application Programming Interface
Behavior Tree	Un Behavior Tree es un modelo de ejecución de tareas de forma jerárquica basado en árboles usada en el campo de la robótica y la inteligencia artificial
Blackboard	La Blackboard es la memoria compartida usada en un Behavior Tree. Ésta funciona como un diccionario de pares clave-valor, que pueden ser variables de entrada/salida.
CSV	Comma Separated Values
Embedding	Un embedding es un medio para representar la información compleja de forma numérica. Esto se consigue trasladando la información a un espacio vectorial en el que a cada unidad se le determina unas coordenadas según el contexto que tiene a su alrededor. Así, conceptos cercanos se mantienen matemáticamente cerca y son más sencillos de relacionar.

FAISS	FAISS (Facebook AI Similarity Search) es una librería de Meta que permite la búsqueda y el agrupamiento eficiente de vectores densos con el fin de facilitar la búsqueda por similitud.
Fine-tuning	El Fine-tuning es una técnica de Machine Learning que consiste en reentrenar ciertas partes de modelos ya preentrenados con nuevos datos con el objetivo de especializarlo en un tema concreto.
IA	Inteligencia Artificial
LLM	Un LLM (Large Language Model) es un modelo de aprendizaje automático profundo (deep learning) que ha sido entrenado con grandes cantidades de texto con propósito general de predicción de palabras.
LSTM	Long Short-Term Memory
metaverse	The metaverse is a set of digital spaces to socialize, learn, play and do other activities. (Definition by the company Meta)
NPC	Non Playable Character
Ollama	Ollama es una aplicación basada en el motor de inferencia "llama.cpp" que permite descargar y ejecutar modelos localmente.
RAG	RAG (Retrieval Augmented Generation) es una técnica de Inteligencia Artificial que permite mejorar las respuestas de modelos de lenguaje buscando información en documentos externos que tengan que ver con la pregunta del usuario.
Random Forest	Un random forest es un algoritmo de aprendizaje automático que utiliza múltiples árboles de decisión para mejorar la precisión y la robustez de las predicciones
RNN	Recurrent Neural Network
RPG	Role-Playing Game
Singleton	El patrón Singleton es un patrón de programación que consiste en garantizar que una clase tenga una instancia única y que se pueda acceder globalmente a ésta.
VR	Realidad Virtual

Licencia de uso del documento

Esta obra está bajo una licencia [Creative Commons](http://creativecommons.org/licenses/by-sa/4.0/legalcode) «Atribución-NoComercial-CompartirIgual 4.0 Internacional».



<http://creativecommons.org/licenses/by-sa/4.0/legalcode>.

Licencia de uso del código fuente